

Ciência de Dados – Aula 08 (Parte 1)

Revisão Aprofundada de Probabilidade, Amostragem e Propriedades da Média
Guia Explicativo Detalhado de Equações e Estudos de Caso

Curso de Análise e Desenvolvimento de Sistemas (ADS)

Disciplina: Ciência de Dados

21 de julho de 2026

Agenda Explicativa da Parte 1

1. Revisão Detalhada de Probabilidade para ADS
2. Amostragem Aleatória em Python
3. A Média e suas Propriedades Fundamentais
4. Média vs. Mediana e Assimetria (Skewness)

1.1 Espaço Amostral, Experimentos e Eventos

Definições Fundamentais em Ciência de Dados

- **Experimento Aleatório:** Qualquer ação ou processo observável cujo resultado final não pode ser determinado com certeza absoluta antes da execução (ex: envio de requisição web, sorteio de usuário).
- **Espaço Amostral (Ω):** O conjunto de **todos** os resultados possíveis do experimento.
- **Evento (A):** Qualquer subconjunto do espaço amostral ($A \subseteq \Omega$).

Fórmula da Probabilidade Clássica (Resultados Equiprováveis)

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{Número de resultados favoráveis ao evento } A}{\text{Número total de resultados possíveis no espaço amostral } \Omega}$$

Significado das Variáveis e Símbolos:

- $P(A)$: Probabilidade de ocorrência do evento A (número real entre 0 e 1).
- $|A|$: Cardinalidade do conjunto A (quantidade de elementos no evento A).
- $|\Omega|$: Cardinalidade do espaço amostral Ω (quantidade total de resultados possíveis).

1.2 Regra da Adição e União de Eventos: $P(A \cup B)$

Eventos Mutuamente Exclusivos

Dois eventos A e B são **mutuamente exclusivos** (ou disjuntos) se nunca puderem ocorrer simultaneamente no mesmo experimento ($A \cap B = \emptyset$).

$$P(A \cup B) = P(A) + P(B)$$

Regra Geral da Adição (Eventos Não-Exclusivos)

Quando existe sobreposição entre os eventos ($A \cap B \neq \emptyset$):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Explicação das Variáveis:

- $P(A \cup B)$: Probabilidade de ocorrer o evento A **OU** o evento B (União de conjuntos).
- $P(A)$: Probabilidade individual de ocorrência do evento A .
- $P(B)$: Probabilidade individual de ocorrência do evento B .
- $P(A \cap B)$: Probabilidade de ocorrerem **AMBOS** os eventos ao mesmo tempo (Interseção).
- **Por que subtrair $P(A \cap B)$?** Na soma $P(A) + P(B)$, a região de interseção é contada **duas**

1.3 Probabilidade Condicional e Regra da Multiplicação

Regra Geral da Multiplicação

Para quaisquer dois eventos A e B , a probabilidade de ambos ocorrerem é:

$$P(A \cap B) = P(A) \cdot P(B|A)$$

Explicação Detalhada das Variáveis:

- $P(A \cap B)$: Probabilidade de ocorrer A e B em sequência ou simultaneamente.
- $P(A)$: Probabilidade do primeiro evento A ocorrer.
- $P(B|A)$: Probabilidade condicional de B ocorrer **dado que A já ocorreu**.

Estudo de Caso Explicado: Sorteio Sem Reposição

Problema: Em um grupo de 3 alunos $\{X, Y, Z\}$, qual a probabilidade de sortear Y no 1º turno e X no 2º turno sem reposição?

- **Passo 1 (Evento A):** Probabilidade de tirar Y primeiro $\implies P(A) = \frac{1}{3}$.
- **Passo 2 (Evento $B|A$):** Com Y fora, restam 2 alunos $\{X, Z\}$. Probabilidade de tirar X em seguida $\implies P(B|A) = \frac{1}{2}$.
- **Solução e Resposta Final:** $P(A \cap B) = \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{6} \approx 0,1667$ (ou 16,67%).

1.4 Independência de Eventos e a Crise Financeira de 2008

Definição Formal de Independência

Dois eventos A e B são **independentes** se a ocorrência de A não altera a probabilidade de B ocorrer ($P(B|A) = P(B)$).

$$P(A \cap B) = P(A) \cdot P(B) \quad (\text{Válido APENAS para eventos independentes})$$

Estudo de Caso Explicado: A Falha da Suposição de Independência em 2008

O Problema Real: Durante a crise dos títulos imobiliários de 2008, modelos financeiros assumiram que a inadimplência de hipotecas em diferentes cidades eram eventos **independentes**.

- **Cálculo Errado do Mercado:** Se $P(\text{Inadimplência em Cidade A}) = 5\%$ e em Cidade B = 5%, calcularam a probabilidade de falha dupla como:

$$P(A \cap B) = 0,05 \times 0,05 = 0,0025 \quad (0,25\% - \text{Risco quase zero!})$$

- **Como Chegamos à Resposta Real:** As economias estavam interligadas (fatores sistêmicos). A inadimplência na Cidade A aumentava a chance de inadimplência na Cidade B ($P(B|A) \gg P(B)$). A falta de independência causou o colapso dos modelos!

[LIVE CODING] Prática 1: Probabilidade em Python

[PRÁTICA EM SALA] Execução no Notebook (Célula 2)

Simulando o cálculo empírico de probabilidade condicional e união:

```
import numpy as np

# Simulando 10.000 lançamentos de 2 moedas
np.random.seed(42)
m1 = np.random.choice(['H', 'T'], size=10000)
m2 = np.random.choice(['H', 'T'], size=10000)

# Evento: Pelo menos uma cara (H) ->  $P = 3/4 = 75\%$ 
p_pelo_menos_uma_cara = np.mean((m1 == 'H') | (m2 == 'H'))
print(f"P(Pelo menos 1 Cara) observada: {p_pelo_menos_uma_cara:.2%}")

# Multiplicacao sem reposicao ( $1/3 * 1/2 = 1/6$ )
p_yx = (1/3) * (1/2)
print(f"P(Y1o e X2o sem reposicao): {p_yx:.4f} (Teorico: 0.1667)")
```

2.1 População vs. Amostra e Tipos de Amostragem

Parâmetro Populacional vs. Estatística Amostral

- **População:** O conjunto total e absoluto de todos os elementos estudados (N maiúsculo). Parâmetro populacional é fixo (ex: média populacional μ).
- **Amostra:** Um subconjunto aleatório extraído da população (n minúsculo). Estatística amostral varia a cada amostra (ex: média amostral $\bar{x}$).

Amostragem COM Reposição

Cada elemento sorteado retorna ao conjunto antes do próximo sorteio.

- Resultados são **independentes**.
- Espaço amostral não muda de tamanho.

Amostragem SEM Reposição

Cada elemento sorteado é removido permanentemente.

- Resultados são **independentes** (probabilidades mudam).
- Utilizado em amostragem aleatória simples de bancos de dados.

[LIVE CODING] Prática 2: Amostragem com NumPy e Pandas

[PRÁTICA EM SALA] Amostragem de DataFrames

Executando amostragem aleatória simples em conjuntos de dados:

```
import pandas as pd

populacao = np.array(['Aluno_A', 'Aluno_B', 'Aluno_C', 'Aluno_D', 'Aluno_E'])

# Sorteio COM reposicao
print("COM_reposicao:", np.random.choice(populacao, size=3, replace=True))

# Sorteio SEM reposicao
print("SEM_reposicao:", np.random.choice(populacao, size=3, replace=False))

# Amostragem direta de um DataFrame no Pandas
df_users = pd.DataFrame({'id': range(100), 'ativo': np.random.choice([0,1], 100)})
amostra = df_users.sample(n=5, random_state=42)
print("Amostra_DataFrame:\n", amostra)
```

3.1 Média Aritmética como Operação de Suavização (*Smoother*)

Fórmula da Média Aritmética Simples

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{x_1 + x_2 + \dots + x_N}{N}$$

Significado Explicado das Variáveis:

- $\bar{x}$ (lê-se "x-barra"): A média aritmética do conjunto de dados.
- N : Número total de elementos/observações na coleção.
- x_i : O valor individual do i -ésimo elemento da coleção.
- $\sum_{i=1}^N$: Símbolo de somatório do primeiro elemento ($i = 1$) até o último ($i = N$).

Conceito do Fundo Comum (Equalizador)

Para a coleção $\{2, 3, 3, 9\}$:

$$\text{Total} = 2 + 3 + 3 + 9 = 17 \implies \bar{x} = \frac{17}{4} = 4,25$$

Se juntarmos todos os \$17 em um fundo comum e redistribuirmos igualmente, cada indivíduo recebe \$4,25. A média suaviza as disparidades individuais.

3.2 Proporções são Médias de Variáveis Binárias

Matemática das Variáveis Indicadoras (0 e 1)

Em sistemas de informação, dados binários ou booleanos são representados por $x_i \in \{0, 1\}$.

$$\text{Proporção de 1s} = \bar{x} = \frac{\sum_{i=1}^N x_i}{N} = \frac{\text{Número total de 1s (Sucessos)}}{\text{Número total de elementos } N}$$

Aplicações Práticas explicadas para ADS

- **Taxa de Clique (CTR):** Se um usuário clicou (1) ou não (0). A média do vetor binário é exatamente o CTR.
- **Acurácia de Modelo de Machine Learning:** Comparação ($y_{\text{real}} == y_{\text{pred}}$) gera um vetor de True (1) e False (0). A média resulta na acurácia percentual!

3.3 O Centro de Gravidade do Histograma

Cálculo da Média por Ponderação de Frequências Relativas

Agrupando os valores distintos x_j ponderados pelas suas proporções p_j :

$$\bar{x} = \sum_{j=1}^k x_j \cdot p_j$$

Significado Explicado das Variáveis:

- x_j : Cada valor **distinto** presente no conjunto de dados.
- p_j : A **frequência relativa (proporção)** com que o valor x_j aparece na coleção ($p_j = \text{frequência}/N$).
- k : Quantidade de valores distintos na coleção.

Demonstração Passo a Passo para $\{2, 3, 3, 9\}$

- Valor 2: aparece 1 vez em 4 $\implies p_1 = 1/4 = 0,25$.
- Valor 3: aparece 2 vezes em 4 $\implies p_2 = 2/4 = 0,50$.
- Valor 9: aparece 1 vez em 4 $\implies p_3 = 1/4 = 0,25$.
- **Cálculo Ponderado:** $\bar{x} = (2 \cdot 0,25) + (3 \cdot 0,50) + (9 \cdot 0,25) = 0,5 + 1,5 + 2,25 = 4,25$.

4.1 O Mito do "Abaixo da Média"

Desmistificando a Relação Média vs. Mediana

Pergunta: "Se tirar nota 4 em uma prova onde a média foi 4.25, estou na metade inferior da turma?"

- **Resposta: Não necessariamente!**
- **Explicação Detalhada:** Na distribuição de notas $\{2, 3, 3, 9\}$, a média é 4,25 e a mediana é 3,00. Os elementos 2, 3, 3 estão todos abaixo da média. Portanto, **75% da turma está abaixo da média!**
- **Por que isso ocorre?** A média é o ponto de equilíbrio de massa, não o ponto de corte de 50% dos dados (que é a mediana).

4.2 Estudo de Caso Explicado: Salários de San Francisco (SF 2015)

O Problema Real de Negócio e Dados

Análise da folha de pagamento de San Francisco em 2015 ($N > 30.000$ servidores).

- **Mediana Observada:** $\approx \$99.359$
- **Média Observada:** $\approx \$111.943$
- **Diferença:** A média é R\$ 12.584 **maior** do que a mediana!

Como Chegamos à Explicação e Solução

- **Causa:** O histograma tem assimetria à direita (*Right Skewed*), com uma cauda longa formada por médicos e altos executivos com salários de até \$600.000.
- **Decisão de ADS:** Para relatar o salário do funcionário público "típico", deve-se usar a **Mediana** (resistente a outliers). Para planejar o orçamento total da prefeitura, deve-se usar a **Média** (Orçamento Total = $N \times \text{Média}$).

Síntese da Aula 1

- ① **Probabilidade:** Espaço amostral Ω , união $P(A \cup B)$ e produto condicional $P(A \cap B) = P(A)P(B|A)$.
- ② **Amostragem:** Com reposição (independente) vs. sem reposição (dependente).
- ③ **Média:** Ponto de equilíbrio $\bar{x} = \sum x_j p_j$ e equivalência com proporções para dados binários.
- ④ **Assimetria:** A média desliza na direção da cauda longa; a mediana reflete o ponto central de 50%.