

Ciência de Dados – Aula 08 (Parte 2)

Variabilidade, Curva Normal, Teorema do Limite Central e Tamanho de Amostra
Explicação Detalhada de Fórmulas, Variáveis e Solução dos Estudos de Caso

Curso de Análise e Desenvolvimento de Sistemas (ADS)

Disciplina: Ciência de Dados

21 de julho de 2026

Agenda da Parte 2

1. Medindo a Variabilidade: Desvio Padrão (SD) e Z-Scores
2. Limite de Chebyshev e a Curva Normal
3. O Teorema do Limite Central (TLC)
4. A Lei da Raiz Quadrada e Acurácia
5. Aplicação Prática em ADS: Tamanho de Amostra Mínimo

1.1 A Necessidade de Medir a Dispersão dos Dados

Por que a Média Sozinha Pode Ser Enganosa?

Duas distribuições podem apresentar **exatamente a mesma média**, mas comportamentos de espalhamento totalmente distintos.

- Coleção A: $\{4, 4, 4, 4\} \implies$ Média = 4, Sem dispersão (Variabilidade Zero)
- Coleção B: $\{-10, 0, 8, 18\} \implies$ Média = 4, Alta dispersão ao redor da média

O Desvio Padrão (Standard Deviation - SD)

O **Desvio Padrão (SD)** mede a distância "típica" ou média das observações em relação à média do conjunto.

$$\text{Desvio Individual} = x_i - \bar{x}$$

$$\text{SD} = \sqrt{\text{Variância}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

- SD: Desvio Padrão (na mesma unidade de medida dos dados originais).
- N : Quantidade total de observações na coleção.
- x_i : Valor do i -ésimo elemento.
- $\bar{x}$: Média aritmética dos dados.

1.2 Unidades Padrão (Z-Scores) e Normalização

Fórmula do Z-Score (Padronização)

$$z = \frac{x - \bar{x}}{SD}$$

Significado Explicado das Variáveis:

- z : O valor em **Unidades Padrão (Z-score)**. Mede **quantos desvios padrões** o valor x está acima ($z > 0$) ou abaixo ($z < 0$) da média.
- x : O valor bruto observado.
- $\bar{x}$: Média do conjunto de dados.
- SD : Desvio padrão do conjunto de dados.

Aplicação Essencial em Machine Learning (ADS)

- **Normalização de Features (StandardScaler)**: Algoritmos como K-NN, Regressão Logística e Redes Neurais exigem que atributos com escalas diferentes (ex: Idade [20-60] e Renda [2000-50000]) sejam convertidos para Z-scores (z) para que nenhuma variável domine o cálculo de distância.

[LIVE CODING] Prática 1: Estudo de Caso Passo a Passo do SD

[PRÁTICA EM SALA] Resolução Numérica da Coleção {1, 2, 2, 10}

Executando a tabela de desvios e Z-scores em Python:

```
import numpy as np
import pandas as pd

any_numbers = np.array([1, 2, 2, 10])
media = np.mean(any_numbers)           # 3.75
desvios = any_numbers - media          # [-2.75, -1.75, -1.75, 6.25]
desvios_quad = desvios ** 2            # [7.5625, 3.0625, 3.0625, 39.0625]
variancia = np.mean(desvios_quad)      # 13.1875
sd = np.sqrt(variancia)                # 3.6314

df_calculo = pd.DataFrame({
    'x': any_numbers,
    'x - media': desvios,
    '(x - media)^2': desvios_quad,
    'Z-score': (any_numbers - media) / sd
})
print(df_calculo)
print(f"Resultado Final: Media={media:.2f}, Variancia={variancia:.2f}, SD={sd:.2f}")
```

2.1 Desigualdade de Chebyshev e a Regra Empírica

Desigualdade de Chebyshev (Validade Universal para Qualquer Formato)

Para **qualquer conjunto de dados** (mesmo com assimetria severa):

$$\text{Proporção de dados em } (\bar{x} - k \cdot \text{SD}, \bar{x} + k \cdot \text{SD}) \geq 1 - \frac{1}{k^2}$$

Significado da Variável k : Número de desvios padrões ($k > 1$).

- Para $k = 2 \implies 1 - 1/2^2 = 1 - 1/4 = 0,75 \implies$ **Pelo menos 75% dos dados** estão em Média ± 2 SD.

A Regra Empírica para Distribuições Normais (68% – 95% – 99,7%)

Quando o histograma tem formato de sino (Curva Normal):


- $\bar{x} \pm 1$ SD contém $\approx 68,27\%$ dos dados.
- $\bar{x} \pm 2$ SD contém $\approx 95,45\%$ dos dados.
- $\bar{x} \pm 3$ SD contém $\approx 99,73\%$ dos dados.

2.2 Os Pontos de Inflexão da Curva Normal

Identificando o SD Visualmente no Histograma

Em uma Curva Normal Padrão:

- O pico central está na média ($\bar{x}$).
- Os **pontos de inflexão** (onde a curva muda de côncava para convexa) ocorrem exatamente em $z = +1$ e $z = -1$.



[LIVE CODING] Prática 2: Áreas Acumuladas com `scipy.stats`

[PRÁTICA EM SALA] Função CDF (Cumulative Distribution Function)

Calculando as probabilidades da Regra Empírica em Python:

```
from scipy import stats

# norm.cdf(z) calcula  $P(Z \leq z)$ 
area_1sd = stats.norm.cdf(1) - stats.norm.cdf(-1) # Média +- 1 SD
area_2sd = stats.norm.cdf(2) - stats.norm.cdf(-2) # Média +- 2 SD
area_3sd = stats.norm.cdf(3) - stats.norm.cdf(-3) # Média +- 3 SD

print(f"Área entre Média +- 1 SD: {area_1sd:.2%} (Esperado: 68.27%)")
print(f"Área entre Média +- 2 SD: {area_2sd:.2%} (Esperado: 95.45%)")
print(f"Área entre Média +- 3 SD: {area_3sd:.2%} (Esperado: 99.73%)")
```

3.1 Enunciado Formal e Equações do TLC

O Teorema do Limite Central (TLC)

Ao extrair uma amostra aleatória grande ($n \geq 30$) com reposição de **qualquer população** com média μ e desvio padrão σ :

- A distribuição de probabilidade da **média amostral** ($\bar{X}$) aproxima-se de uma **Distribuição Normal**:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Explicação Detalhada das Variáveis da Equação

- $\bar{X}$: A variável aleatória correspondente às médias das amostras.
- $\mathcal{N}(\text{Média}, \text{SD})$: Notação da Distribuição Normal.
- μ (mu): Média da população original (centro da curva normal de médias).
- σ (sigma): Desvio padrão da população original.
- n : Tamanho de cada amostra aleatória extraída.
- $\frac{\sigma}{\sqrt{n}}$: O **Erro Padrão da Média (Standard Error - SE)**.

[LIVE CODING] Prática 3: Demonstração Prática do TLC

[PRÁTICA EM SALA] Experimento de Atrasos de Voos

Demonstrando em código como a distribuição das médias torna-se normal:

```
np.random.seed(42)
populacao_atrasos = np.random.exponential(scale=15, size=10000) # Assimetrica!

# Extraindo 10.000 amostras de tamanho N=100
amostras = np.random.choice(populacao_atrasos, size=(10000, 100))
medias = np.mean(amostras, axis=1)

sd_pop = np.std(populacao_atrasos)
sd_teorico = sd_pop / np.sqrt(100)
sd_observado = np.std(medias)

print(f"Media_Populacional: {np.mean(populacao_atrasos):.2f}")
print(f"Media_das_Medias: {np.mean(medias):.2f}")
print(f"SD_Teorico (sigma / sqrt(n)): {sd_teorico:.2f}")
print(f"SD_Observado_das_Medias: {sd_observado:.2f}")
```

4.1 A Lei da Raiz Quadrada e o Custo da Precisão

Análise da Fórmula da Acurácia

$$\text{SD da Média Amostral} = \frac{\sigma}{\sqrt{n}}$$

Como n está sob uma raiz quadrada no denominador:

Exemplo Explicado: Quadruplicar n

Se a amostra aumentar de $n = 25$ para $n = 100$ ($4\times$ maior):

$$\text{Erro Padrão} = \frac{\sigma}{\sqrt{100}} = \frac{\sigma}{10} = \frac{1}{2} \cdot \left(\frac{\sigma}{\sqrt{25}} \right)$$

Resultado: O erro cai pela metade ($\sqrt{4} = 2$). A precisão **dobra**.

Exemplo Explicado: Aumentar Precisão por $10\times$

Para reduzir a variabilidade por um fator de 10:

$$\sqrt{n_{\text{novo}}} = 10 \cdot \sqrt{n} \implies n_{\text{novo}} = 100 \cdot n$$

Resultado: É necessário aumentar o tamanho de amostra em **100 vezes**!

5.1 Estudo de Caso Explicado: Pesquisa Eleitoral (Candidato A)

O Problema do Cientista de Dados

Deseja-se estimar a proporção de votos do Candidato A com um intervalo de confiança de 95% e largura total máxima de **1%** (0,01). Qual o tamanho de amostra mínimo (n) garantido?

Resolução Passo a Passo e Explicação da Fórmula

- ❶ **Largura do Intervalo de 95%:** Na Normal, o intervalo abrange 4 SDs de cada lado (± 2 SDs).

$$4 \times \text{SD da Proporção Amostral} \leq 0,01 \implies 4 \times \frac{\text{SD}_{\text{pop}}}{\sqrt{n}} \leq 0,01$$

- ❷ **Cota Superior para SD Binário (0/1):** O desvio padrão máximo de qualquer população binária ocorre quando $P = 0,5$ (50% sim, 50% não):

$$\text{SD}_{\text{max}} = \sqrt{0,5 \times (1 - 0,5)} = 0,5$$

- ❸ **Isolando o tamanho de amostra n :**

$$\sqrt{n} \geq 4 \times \frac{0,5}{0,01} = \frac{2}{0,01} = 200 \implies n \geq 200^2 = 40.000$$

- ❹ **Resposta Final Explicada:** São necessários no mínimo **40.000 eleitores** para garantir a precisão de 1% em 95% de confiança.

5.2 Estudo de Caso Explicado: Latência de API Web em ADS

O Problema Real de Engenharia de Software

Uma API de pagamento processa 1.000 requisições: 95% respondem em $\approx 100\text{ms}$, mas 5% sofrem atraso/timeout ($\approx 3000\text{ms}$).

- **Média Calculada:** 268,39 ms
- **Mediana Calculada:** 100,59 ms

Solução Passo a Passo para o Engenheiro de ADS

- **Para o SLA do Cliente (Painel do Usuário):** Usar a **Mediana** (100,59ms) ou o Percentil 95/99. A média de 268ms faria parecer que a maioria dos usuários experiência lentidão, o que é falso para 95% dos acessos!
- **Para o Dimensionamento do Servidor (Infraestrutura):** Usar a **Média** (268,39ms), pois o tempo total de processamento exigido da CPU é $N \times \text{Média} = 1000 \times 268,39 = 268.390\text{ms}$.

Síntese dos Conceitos de Ciência de Dados para ADS

- ➊ **Probabilidade e Amostragem:** Regras da adição, multiplicação e amostragem com/sem reposição em Python.
- ➋ **Propriedades da Média:** Ponto de equilíbrio do histograma $\bar{x} = \sum x_j p_j$ e representação de proporções binárias.
- ➌ **Média vs. Mediana:** Mediana é robusta a assimetrias; Média é atraída pela cauda longa.
- ➍ **Desvio Padrão e Z-Scores:** Medição de dispersão e padronização para Machine Learning.
- ➎ **Teorema do Limite Central:** A média de amostras grandes é Normal, com variabilidade $\sigma/\sqrt{n}$.
- ➏ **Dimensionamento n :** Aplicação da Lei da Raiz Quadrada para garantir margens de erro em projetos reais.