

Ciência de Dados – Aula 09

Intervalos de Confiança Paramétricos e Testes de Hipóteses

Abordagens Empíricas via Simulação e Paramétricas via Teorema do Limite Central

Curso de Análise e Desenvolvimento de Sistemas (ADS)

Disciplina: Ciência de Dados

28 de julho de 2026

Agenda da Aula 09

1. Motivação Real e Conceito de Intervalo de Confiança (IC)
2. Abordagem 1: IC e Teste de Hipóteses via Simulação Empírica
3. Abordagem 2: IC Paramétrico via Teorema do Limite Central (TCL)
4. Condições de Validade e Dinâmica do Tamanho do IC
5. Desafio Prático em Python para ADS

1.1 Motivação Real: O Estudo da COVID-19 (UFPeI 2020)

O Problema Real de Saúde Pública e Decisão

Em maio de 2020, cientistas da Universidade Federal de Pelotas (UFPeI) realizaram um estudo nacional de testagem sorológica para estimar a proporção de infectados por COVID-19 no Brasil.

- **Resultado da Amostra:** Prevalência estimada em 1,9%.
- **Margem de Erro Comunicada:** Intervalo de Confiança de 95% entre [1,7%, 2,1%].

Testando a Hipótese de Imunidade de Rebanho

Pergunta: "O Brasil atingiu a imunidade de rebanho (necessário pelo menos 50% de soropositivos)?"

- **Resposta Explicada:** Não! Mesmo considerando a incerteza amostral, o valor de 50% está extremamente distante do intervalo [1,7%, 2,1%].
- **Conclusão:** Rejeita-se a hipótese de imunidade de rebanho com menos de 5% de chance de erro.

1.2 O que é um Intervalo de Confiança (IC)?

Definição Formal de Intervalo de Confiança

Um **Intervalo de Confiança de 95%** para um parâmetro populacional (como a média μ) é um intervalo numérico calculado a partir de dados amostrais tal que:

- Se o experimento de amostragem for repetido 100 vezes nas mesmas condições, **95 desses intervalos conterão a verdadeira média da população (μ)**.

Desmistificando Erros Comuns de Interpretação

- **[INCORRETO]:** "Há 95% de chance de um indivíduo aleatório estar dentro do IC." (IC não fala de indivíduos brutos!)
- **[INCORRETO]:** "95% dos dados da amostra estão dentro do IC." (IC não mede dispersão de dados!)
- **[CORRETO]:** "Estimamos que a **média esperada da população** está entre o limite inferior e o limite superior com 95% de confiança (5% de chance de erro de amostragem)."

2.1 Estudo de Caso Explicado: O Teste da Moeda Viesada

O Problema do Experimento

Você joga uma moeda para cima 30 vezes. A moeda cai em **cara 22 vezes**. **Pergunta de Teste:** "A moeda é justa (não-viesada) ou possui vício a favor de cara?"

Resolução via Abordagem Empírica (Sem Fórmulas Decoradas)

- 1 **Hipótese Nula (H_0):** A moeda é justa ($P(\text{Cara}) = 0,5$). Sob H_0 , esperamos $30 \times 0,5 = 15$ caras.
- 2 **Simulação Computacional:** Repetir 10.000 vezes o experimento de jogar 30 moedas justas e contar o número de caras.
- 3 **Construção do Intervalo Empírico de 95%:** Extrair os percentis empíricos 2,5% e 97,5% das 10.000 simulações.
- 4 **Resultado:** O intervalo de 95% para uma moeda justa em 30 jogadas é $[10, 20]$ **caras**.
- 5 **Decisão Final:** Como 22 caras está **fora** do intervalo $[10, 20]$, a chance de ver 22 caras ao acaso em uma moeda justa é de apenas 0,69% ($p < 0,05$). **Rejeitamos a hipótese de moeda justa!**

[LIVE CODING] Prática 1: Simulação da Moeda Viesada em Python

[PRÁTICA EM SALA] Execução do Teste Empírico via Percentis

Executando a simulação de 10.000 lançamentos no Python:

```
import numpy as np

# Simulando 10.000 experimentos de 30 moedas sob H0 (p=0.5)
np.random.seed(42)
simulacoes = np.random.binomial(n=30, p=0.5, size=10000)

ic_low = np.percentile(simulacoes, 2.5) # 10
ic_high = np.percentile(simulacoes, 97.5) # 20
p_valor = np.mean(simulacoes >= 22) # 0.0069 (0.69%)

print(f"Intervalo Empirico de 95% sob H0: [{ic_low:.0f}, {ic_high:.0f}] caras")
print(f"P-Valor (Probabilidade de N >= 22): {p_valor:.4f}")

if p_valor < 0.05:
    print("Rejeitamos H0! A moeda possui vies estatisticamente significativo.")
```

3.1 A Equação do IC Paramétrico e Suas Variáveis

Fórmula Geral do Intervalo de Confiança Paramétrico

$$IC = \bar{x} \pm z^* \cdot SE = \bar{x} \pm z^* \cdot \frac{s}{\sqrt{n}}$$

Significado Explicado de Cada Símbolo e Variável:

- $\bar{x}$ (x-barra): **Média amostral** calculada a partir dos dados (estimador pontual da média populacional μ).
- z^* : **Valor crítico** da Distribuição Normal Padrão associado ao nível de confiança escolhido.
 - Para 95% de confiança $\implies z^* = 1,96$.
 - Para 98% de confiança $\implies z^* = 2,33$.
 - Para 99% de confiança $\implies z^* = 2,58$.
- s : **Desvio padrão amostral** (medida de dispersão dos dados brutos).
- n : **Tamanho da amostra** (quantidade de observações coletadas).
- $SE = \frac{s}{\sqrt{n}}$: **Erro Padrão da Média (Standard Error)**, que mede a variabilidade da estimativa amostral.
- Margem de Erro $= z^* \cdot \frac{s}{\sqrt{n}}$: O raio de incerteza adicionado e subtraído da média.

3.2 Estudo de Caso Explicado: Rendimento Acadêmico (RSG UFMG)

O Problema dos Dados Amostrais

Entrevistou-se uma amostra aleatória de $n = 50$ **alunos** do curso de Computação da UFMG sobre seu Rendimento Semestral Global (RSG).

- **Média Amostral ($\bar{x}$):** 3,20
- **Desvio Padrão Amostral (s):** 1,74

Qual é a estimativa da média real de RSG de toda a população de alunos com 95% de confiança?

Resolução Passo a Passo

- ➊ **Cálculo do Erro Padrão (SE):** $SE = \frac{s}{\sqrt{n}} = \frac{1,74}{\sqrt{50}} = \frac{1,74}{7,071} \approx 0,2461$.
- ➋ **Cálculo da Margem de Erro (ME):** $ME = 1,96 \times 0,2461 \approx 0,4823 \approx 0,49$.
- ➌ **Construção do Intervalo:** $IC = (3,20 - 0,49, 3,20 + 0,49) = (2,71, 3,69)$.
- ➍ **Resposta Final Explicada:** Estimamos que a média populacional do RSG dos alunos está entre 2,71 e 3,69 com 95% de confiança.

[LIVE CODING] Prática 2: IC Paramétrico do RSG em Python

[PRÁTICA EM SALA] Execução do Cálculo de IC com scipy.stats

Calculando os limites e o erro padrão exato do RSG:

```
from scipy import stats
import numpy as np

n = 50
xbar = 3.2
s = 1.74

# 1. Erro Padrao (SE)
se = s / np.sqrt(n) # 0.2461

# 2. Valor critico z* para 95% (1.96)
z_95 = stats.norm.ppf(0.975)

# 3. Margem de Erro e Intervalo
margem = z_95 * se # 0.4823
ic_low, ic_high = xbar - margem, xbar + margem

print(f"SE: {se:.4f} | Margem de Erro: {margem:.4f}")
print(f"Intervalo de Confiança de 95%: ({ic_low:.2f}, {ic_high:.2f})")
```

4.1 Condições Obrigatórias para Usar o IC Paramétrico

Para que o IC via TCL Funcione, Exigem-se 2 Condições:

① Independência entre as Observações:

- A amostra deve ser não-viesada.
- Se entrevistarmos apenas alunos de um mesmo laboratório, a amostra é viesada. Deve-se amostrar alunos de diferentes institutos/escolas.

② Tamanho de Amostra Mínimo ($n \geq 30$):

- O Teorema do Limite Central garante a distribuição normal das médias apenas para n suficientemente grande ($n \geq 30$).
- Para amostras pequenas ($n < 30$), deve-se utilizar a **Distribuição t de Student** ou **Bootstrap**.

4.2 Como Alterar a Largura do Intervalo de Confiança?

Análise dos Fatores da Fórmula: $IC = \bar{x} \pm z^* \cdot \frac{s}{\sqrt{n}}$

Como desenvolvedores e analistas de dados, podemos manipular a precisão do IC:

Variando o Nível de Confiança (z^*)

- Aumentar a confiança (95% $\rightarrow$ 98% $\rightarrow$ 99%) aumenta o valor de z^* (1,96 $\rightarrow$ 2,33 $\rightarrow$ 2,58).
- **Efeito:** O intervalo fica **MAIS LARGO**.
- *Trade-off:* Maior certeza, porém menor precisão.

Variando o Tamanho da Amostra (n)

- Aumentar n reduz o erro padrão $SE = s/\sqrt{n}$.
- **Efeito:** O intervalo fica **MAIS ESTREITO**.
- *Vantagem:* Maior precisão sem perder a confiança de 95%!

[LIVE CODING] Prática 3: Tabela de Sensibilidade de Confiança em Python

[PRÁTICA EM SALA] Comparando Confianças de 90%, 95%, 98% e 99%

Visualizando como o intervalo expande ao aumentar a confiança:

```
confs = [0.90, 0.95, 0.98, 0.99]
for c in confs:
    z = stats.norm.ppf(1 - (1 - c)/2)
    me = z * se
    print(f"Confiança: {c:.0%} | z*: {z:.3f} | Margem: {me:.3f} | IC: ({xbar-me:.2f}, {xbar+me:.2f})")
```

Nível de Confiança	Valor Crítico (z^*)	Margem de Erro (ME)	Intervalo de Confiança (RSG)
90%	1,645	0,405	(2,80, 3,60)
95%	1,960	0,482	(2,72, 3,68)
98%	2,326	0,572	(2,63, 3,77)
99%	2,576	0,634	(2,57, 3,83)

[LIVE CODING] Desafio Prático: Calculadora Automática de IC para Latência de API

[DESAFIO EM SALA] Criando uma Função Reutilizável em Python

Construa uma função que receba uma série de latências de software e retorne o IC de 95%:

```
def calcular_ic_api(dados, confianca=0.95):
    n_elem = len(dados)
    xbar_elem = np.mean(dados)
    s_elem = np.std(dados, ddof=1)
    se_elem = s_elem / np.sqrt(n_elem)
    z_critico = stats.norm.ppf(1 - (1 - confianca)/2)
    margem_elem = z_critico * se_elem
    return xbar_elem, (xbar_elem - margem_elem, xbar_elem + margem_elem), margem_elem

np.random.seed(123)
latencias_api = np.random.normal(loc=120, scale=25, size=60)
media_api, (ic_l, ic_h), me_api = calcular_ic_api(latencias_api)

print(f"Media Amostral da API: {media_api:.2f}ms")
print(f"IC 95% do Tempo Medio: ({ic_l:.2f}ms, {ic_h:.2f}ms) | Margem: +- {me_api:.2f}ms")
```

Síntese do Aprendizado da Aula 09

- ❶ **Intervalo de Confiança (IC):** Faixa que contém o verdadeiro valor do parâmetro populacional (μ) em 95% das amostragens repetidas.
- ❷ **Abordagem Empírica vs Paramétrica:** Simulações via percentis empíricos de 95% vs Fórmula paramétrica do TCL ($\bar{x} \pm 1,96 \cdot SE$).
- ❸ **Erro Padrão ($SE = s/\sqrt{n}$):** Mede a precisão da média amostral.
- ❹ **Tomada de Decisão:** Se o valor da hipótese nula H_0 cai fora do IC de 95%, a hipótese é **rejeitada** com $p < 0,05$.
- ❺ **Aumentar Precisão:** Aumentar n estreita o intervalo sem perder o nível de confiança.