

Bootstrap e Testes A/B

Análise e Desenvolvimento de Sistemas

Prof. Reginaldo Fernandes
Adaptação Didática

Instituto Federal do Ceará – Campus Tauá
Curso de Tecnologia em Análise e Desenvolvimento de Sistemas

28 de julho de 2026

Sumário da Aula

- 1 Introdução e Problema da Inferência
- 2 O Método Clássico e o Teorema Central do Limite
- 3 O Método Bootstrap
- 4 Testes A/B Computacionais
- 5 Consolidação e Exercícios

Como Conhecer a População?

O Problema da Inferência

- Temos acesso apenas a uma **amostra** de tamanho N .
- Nosso objetivo é descrever ou estimar propriedades da **população** (como a média μ).
- Não temos orçamento ou meios para auditar a população completa.

As Duas Abordagens Principais

- 1 **Abordagem Clássica:** Utiliza fórmulas matemáticas baseadas em suposições rígidas de distribuição (ex: Teorema Central do Limite).
- 2 **Abordagem Computacional:** Utiliza simulação e reamostragem a partir dos próprios dados observados (Bootstrap).

O que é um Teste A/B?

Definição Básica

Um experimento controlado para comparar duas versões de uma variável (A e B) com o objetivo de determinar qual delas é mais eficaz.

Grupo A (Controle)

- Versão clássica do sistema.
- Experiência do usuário padrão.
- Medicamento placebo (em saúde).

Grupo B (Tratamento)

- Nova funcionalidade ou design.
- Novo layout de checkout rápido.
- Novo princípio ativo.

Queremos provar que a diferença observada entre os grupos é real, e não mera flutuação aleatória!

Exemplo Matemático: Estimativa de Parâmetros

Problema de Negócio

Imagine que medimos o tempo de carregamento de uma página em 5 visitas (em segundos):

$$X = \{1.5, 2.3, 1.8, 3.0, 2.4\}$$

A estimativa pontual da média populacional μ é a média amostral $\bar{X}$:

$$\bar{X} = \frac{1.5 + 2.3 + 1.8 + 3.0 + 2.4}{5} = \frac{11.0}{5} = 2.2 \text{ s}$$

Questão Fundamental

Essa estimativa pontual (2.2 s) é representativa? Se coletarmos outra amostra de 5 visitas, qual será a variação da média?

Demonstração em Python: Média Amostral e Variabilidade

```
import numpy as np

# Amostra de tempos de carregamento (em segundos)
X = np.array([1.5, 2.3, 1.8, 3.0, 2.4])

# Estimativa pontual da media
media_amostrual = np.mean(X)
print(f"Media amostral: {media_amostrual:.2f} s")
# Saída: Media amostral: 2.20 s

# Simulando a variabilidade amostral (se a populacao fosse conhecida)
np.random.seed(42)
populacao = np.random.normal(loc=2.2, scale=0.5, size=10000)
novas_medias = [np.random.choice(populacao, size=5).mean() for _ in range(1000)]
print(f"Desvio padrao das medias (erro padrao): {np.std(novas_medias):.3f}")
```

O Teorema Central do Limite (TCL)

Definição

Independentemente da distribuição da população original, a distribuição da média amostral $\bar{X}$ se aproxima de uma distribuição normal à medida que o tamanho da amostra N cresce.

Intervalo de Confiança (IC) Clássico

O intervalo de 95% de confiança para a média é dado por:

$$IC = \bar{X} \pm 1.96 \times \frac{s}{\sqrt{N}}$$

Onde s é o desvio padrão amostral e $\frac{s}{\sqrt{N}}$ é o erro padrão (SE).

Por que o TCL nem sempre é suficiente?

- **Amostras pequenas:** Se a população for muito assimétrica e N for pequeno, a aproximação normal falha.
- **Estatísticas complexas:** E se quisermos construir um intervalo de confiança para a **mediana**, **variância** ou uma razão entre variáveis? A matemática clássica torna-se extremamente complexa ou indisponível.
- **Outliers:** Presença de valores extremos distorce o desvio padrão e o erro padrão.

Solução em Ciência de Dados: Métodos Computacionais (Bootstrap)

Exemplo Matemático: IC via TCL

Problema

Amostra de $N = 36$ tempos de atendimento com média $\bar{X} = 100$ s e desvio padrão $s = 15$ s. Queremos o IC de 95% para a média populacional μ .

Cálculo Analítico (TCL)

- **Erro padrão da média (SE):** $SE = \frac{s}{\sqrt{N}} = \frac{15}{\sqrt{36}} = 2.5$ s
- **Margem de erro (para $z = 1.96$):** $1.96 \times 2.5 = 4.9$ s
- **Intervalo de Confiança (95%):** $IC = 100 \pm 4.9 = [95.1 \text{ s}, 104.9 \text{ s}]$

Demonstração em Python: IC Clássico

```
import numpy as np
import scipy.stats as ss

# Dados amostrais simulados (N=36, media=100, std=15)
np.random.seed(42)
dados = np.random.normal(loc=100, scale=15, size=36)

# Calculos intermediarios
n = len(dados)
media = np.mean(dados)
desvio = np.std(dados, ddof=1) # Desvio padrao amostral
erro_padrao = desvio / np.sqrt(n)

# Encontrando o z critico para 95%
z_critico = ss.norm.ppf(0.975)

# Limites do intervalo
lim_inf = media - z_critico * erro_padrao
lim_sup = media + z_critico * erro_padrao
print(f"IC Classico: [{lim_inf:.2f}, {lim_sup:.2f}]")
# Saída aproximada: IC Classico: [94.59, 104.07]
```

O Princípio do Bootstrap

Origem do Nome

Derivado da expressão "*to pull oneself up by one's own bootstraps*" (erguer-se puxando as próprias botas). Remete a realizar uma tarefa impossível utilizando apenas os recursos disponíveis.

Idéia Central

A amostra observada é a melhor representação disponível da população desconhecida. Reamostrar **com reposição** dessa amostra imita o processo de retirar amostras da própria população original.

O Algoritmo do Bootstrap

- 1 Considere uma amostra original S de tamanho N .
- 2 Crie uma nova amostra (reamostra bootstrap) sorteando N elementos de S **com reposição**.
- 3 Calcule a estatística desejada (ex: média) para essa reamostra.
- 4 Repita os passos 2 e 3 um número elevado de vezes (ex: $M = 5000$).
- 5 Use a distribuição das estatísticas geradas para estimar variabilidade e limites de confiança.

Exemplo Matemático: Bootstrap Manual

Problema

Temos uma amostra inicial pequena $S = \{2, 4, 9\}$ com $N = 3$. A média observada é $\bar{X} = 5.0$. Vamos simular a amostragem com reposição para obter 4 reamostras bootstrap:

Simulações de Reamostragem

- **Reamostra 1:** $\{2, 2, 9\} \rightarrow \bar{X}_1^* = \frac{13}{3} \approx 4.33$
- **Reamostra 2:** $\{4, 9, 9\} \rightarrow \bar{X}_2^* = \frac{22}{3} \approx 7.33$
- **Reamostra 3:** $\{2, 4, 4\} \rightarrow \bar{X}_3^* = \frac{10}{3} \approx 3.33$
- **Reamostra 4:** $\{9, 2, 9\} \rightarrow \bar{X}_4^* = \frac{20}{3} \approx 6.67$

A distribuição das médias bootstrap obtida é $\{3.33, 4.33, 6.67, 7.33\}$. Em escala real, faríamos isso 5000 vezes para obter percentis estáveis.

Demonstração em Python: Bootstrap Manual

```
import numpy as np

# Amostra original
S = np.array([2, 4, 9])
n = len(S)

# Gerando reamostras com reposicao
np.random.seed(42)
m = 4 # Apenas 4 reamostras para ilustrar
medias_bs = []

for i in range(m):
    reamostra = np.random.choice(S, size=n, replace=True)
    media_tmp = reamostra.mean()
    medias_bs.append(media_tmp)
    print(f"Reamostra {i+1}: {reamostra} -> Media: {media_tmp:.2f}")

# Calculo de percentil com 10000 simulacoes para IC de 95%
todas_medias = [np.random.choice(S, size=n, replace=True).mean() for _ in range(10000)]
ic_bs = np.percentile(todas_medias, [2.5, 97.5])
print(f"IC Bootstrap (95%): [{ic_bs[0]:.2f}, {ic_bs[1]:.2f}]" )
```

Implementação da Média via Bootstrap


```
def bootstrap_mean(df, column, n=5000, size=None):
    if size is None:
        size = len(df)
    values = np.zeros(n)
    data_array = df[column].to_numpy()
    for i in range(n):
        # Amostragem com reposicao (replace=True)
        sample = np.random.choice(data_array, size=size, replace=True)
        values[i] = sample.mean()
    return values
```

Intervalo de Confiança Bootstrap

Calculado a partir dos percentis empíricos da distribuição obtida (ex: 2.5% e 97.5%): `np.percentile(values, [2.5, 97.5])`

Demonstração de Convergência

- À medida que aumentamos o número de amostras bootstrap (M), a estimativa empírica se estabiliza.
- Em distribuições padrão, o IC Bootstrap converge para o IC Clássico do TCL.



Duas Abordagens Didáticas

- 1 **Sobreposição de ICs Individuais:** Calcular o IC para cada grupo separadamente e checar se eles se sobrepõem. (Abordagem conservadora).
- 2 **IC da Diferença das Médias (Padrão):** Estimar diretamente a distribuição bootstrap de $\bar{X}_1 - \bar{X}_2$. Se o intervalo correspondente contiver o valor zero, dizemos que não há diferença significativa entre as médias.

Exemplo Matemático: Diferença de Médias via Bootstrap

Problema

Grupos: $X_A = \{10, 15, 20\} \rightarrow \bar{X}_A = 15.0$ e $X_B = \{12, 18, 24\} \rightarrow \bar{X}_B = 18.0$.
Diferença observada: $+3.0$. Vamos reamostrar com reposição:

Simulações de Reamostragem

- **Passo 1:** Reamostras $B_1^* = \{18, 24, 24\}$ (méd. 22.0) e $A_1^* = \{15, 15, 20\}$ (méd. 16.67). Diferença: $22.0 - 16.67 = 5.33$.
- **Passo 2:** Reamostras $B_2^* = \{12, 12, 18\}$ (méd. 14.0) e $A_2^* = \{10, 20, 20\}$ (méd. 16.67). Diferença: $14.0 - 16.67 = -2.67$.

Repetindo 5000 vezes, analisamos se a diferença é significativamente maior que zero.

Demonstração em Python: Teste A/B Simples

```
import numpy as np

# Grupos originais
grupo_A = np.array([10, 15, 20])
grupo_B = np.array([12, 18, 24])

# Simulando a diferença das medias
np.random.seed(42)
diferencas_bs = []

for _ in range(5000):
    resample_A = np.random.choice(grupo_A, size=len(grupo_A), replace=True)
    resample_B = np.random.choice(grupo_B, size=len(grupo_B), replace=True)
    diferencas_bs.append(resample_B.mean() - resample_A.mean())

# Intervalo de Confiança de 95% para a diferença
ic_diferenca = np.percentile(diferencas_bs, [2.5, 97.5])
print(f"IC da diferença (95%): [{ic_diferenca[0]:.2f}, {ic_diferenca[1]:.2f}]")
# Saída: IC da diferença (95%): [-3.67, 9.67]. Contem zero, nao e significativa!
```

Peso de Bebês e Tabagismo Materno

- **Dados:** Amostra de recém-nascidos (baby.csv).
- **Grupo Controle:** Mães não fumantes.
- **Grupo Tratamento:** Mães fumantes.

```
# Código para calcular diferença de médias via bootstrap
def bootstrap_diff(df1, df2, column, n=5000):
    data1 = df1[column].to_numpy()
    data2 = df2[column].to_numpy()
    diff_values = np.zeros(n)
    for i in range(n):
        s1 = np.random.choice(data1, size=len(df1), replace=True)
        s2 = np.random.choice(data2, size=len(df2), replace=True)
        diff_values[i] = s1.mean() - s2.mean()
    return diff_values
```

Código Completo: Carga, Preparação e Bootstrap

```
import pandas as pd
import numpy as np

# 1. Carregar dados da URL
url = 'https://media.githubusercontent.com/media/icd-ufmg/material/master/aulas/10-AB/baby.csv'
df = pd.read_csv(url)

# 2. Conversao de unidades (oncas para kg)
df['Birth Weight'] = 0.0283495 * df['Birth Weight']

# 3. Separar em grupos: Controle vs Tratamento
smokers = df[df['Maternal Smoker'] == True]
no_smokers = df[df['Maternal Smoker'] == False]

# 4. Rodar o bootstrap para a diferenca das medias
np.random.seed(42)
diferencas = bootstrap_diff(smokers, no_smokers, 'Birth Weight', n=5000)

# 5. Calcular o IC de 95 por cento para a diferenca
ic_95 = np.percentile(diferencas, [2.5, 97.5])
print(f"IC 95%: [{ic_95[0]:.3f} kg, {ic_95[1]:.3f} kg]")
```


Resultados: Peso de Bebês

- Média não fumantes: 3.489 kg
- Média fumantes: 3.227 kg
- Diferença observada: -0.263 kg
- IC de 95% para a diferença (Bootstrap): $[-0.323, -0.202]$ kg

Conclusão Estatística

Como o intervalo $[-0.323, -0.202]$ kg **não inclui o valor zero**, rejeitamos a hipótese de igualdade entre as médias. Há diferença estatística significativa.



Visualização: Distribuições de Médias Bootstrap



Interpretação das Médias Individuais

- **Mães Não Fumantes (azul):** A distribuição das médias amostrais $\bar{X}$ (média amostral) está centrada em 3.49 kg, variando no *IC* (Intervalo de Confiança) de [3.45, 3.52] kg.
- **Mães Fumantes (laranja):** A distribuição está centrada em 3.23 kg, variando no *IC* (Intervalo de Confiança) de [3.18, 3.27] kg.
- **Ausência de Sobreposição:** Como os *IC* (Intervalos de Confiança) dos dois grupos não se sobrepõem, há um indício inicial muito forte de que o peso médio populacional é diferente entre os grupos.

Visualização: Diferença de Médias e ECDF



Análise da Diferença e da ECDF

- **Distribuição da Diferença (Esquerda):** Mostra a distribuição de todas as 5.000 diferenças simuladas $\bar{d}^* = \bar{X}_{\text{Fumantes}}^* - \bar{X}_{\text{Não Fumantes}}^*$. O IC (Intervalo de Confiança) de 95% da diferença é $[-0.323, -0.202]$ kg (totalmente abaixo de zero).
- **Curva ECDF (Direita):** A ECDF (Função de Distribuição Acumulada Empírica) chega ao topo (1.0 ou 100% de probabilidade acumulada) bem antes do ponto zero no eixo horizontal.
- **Conclusão:** A probabilidade de a diferença ser maior ou igual a zero é nula ($P(\bar{d}^* \geq 0) = 0$), comprovando o efeito negativo do fumo.


Impacto de Checkout Expresso no Ticket Médio

- **Layout A (Controle):** Checkout em múltiplos passos (250 vendas). Média: R\$44.75.
- **Layout B (Tratamento):** Novo Checkout Expresso (200 vendas). Média: R\$47.29.

Simulação Bootstrap do Ticket Médio

- Diferença de médias observada ($B - A$): +R\$2.53
- IC de 95% da diferença: [R\$0.18, R\$4.90]
- **Conclusão:** Como o limite inferior de R\$0.18 está acima de zero, podemos afirmar que o novo layout gerou aumento de receita.


Visualização: Dispersão do Ticket Médio



Entendendo a Dispersão dos Dados

- **O Boxplot:** O gráfico de caixa mostra a mediana (linha vermelha), a caixa central contendo o *IQR* (Intervalo Interquartil - do 1º ao 3º quartil) e as caudas (limites mínimo e máximo).
- **Layout A (Controle):** Mediana ligeiramente abaixo de 45, com a maioria dos tickets distribuídos de forma simétrica.
- **Layout B (Tratamento):** Mediana claramente acima do Layout A. A caixa inteira e seus quartis estão deslocados para cima.
- **Interpretação:** Embora haja uma grande sobreposição das compras individuais (variabilidade natural), a tendência central do Layout B está visivelmente deslocada para valores mais altos. O Bootstrap nos ajudará a inferir se essa diferença de média é real.

Visualização: Teste A/B E-commerce



Interpretação de Negócio (Checkout Expresso)

- **Efeito Estimado:** A diferença observada de ticket médio ($B - A$) é de +R\$2.53.
- **Decisão Estatística:** O IC (Intervalo de Confiança) de 95% da diferença obtida via Bootstrap é [R\$0.18, R\$4.90].
- **Ausência de Zero:** Como o limite inferior do IC (Intervalo de Confiança) está estritamente acima de zero, o novo Layout B traz um ganho real e não puramente aleatório. Recomendamos implementar em produção.

Quando usar o Bootstrap?

- Distribuições altamente distorcidas (Ex: renda, acessos a servidores).
- Amostras médias e pequenas onde as premissas clássicas falham.
- Ao estimar estatísticas não-lineares (mediana, variâncias, razões).

Armadilhas em Testes A/B

- **Peeking (Espiadinha):** Olhar os resultados do teste toda hora e parar assim que der significância infla falsos positivos.
- **Significância Estatística vs. Prática:** Ganho estatisticamente comprovado de 0,001% pode não valer o custo de engenharia.

- 1 **Modifique para a Mediana:** Altere a função `bootstrap_mean` para calcular a mediana e compare os resultados de renda da base de dados fornecida.
- 2 **Análise do Tamanho Amostral (N):** Varie o tamanho da amostra inicial no script de apoio e responda: Como o tamanho da amostra inicial impacta a largura final do Intervalo de Confiança Bootstrap?
- 3 **Construção de Histograma:** Utilizando o script `aula10_pratica.py`, execute o exemplo de e-commerce, salve a imagem gerada e plote os limites no gráfico.