

Exercício Prático de Fixação: Testes de Hipótese e Permutação (N2)

Contexto: O Impacto da Monitoria no IFCE Campus Tauá

No curso de Tecnologia em Análise e Desenvolvimento de Sistemas do IFCE Campus Tauá, foi implementado um programa piloto de monitoria para a disciplina de Ciência de Dados. Ao final do semestre, o professor Reginaldo coletou as notas finais de dois grupos de alunos para investigar se a participação ativa na monitoria resultou em um desempenho sistematicamente superior.

- **Grupo Monitoria** ($N_A = 12$): Alunos que participaram de pelo menos 75% das sessões de monitoria.
- **Grupo Regular** ($N_B = 15$): Alunos que frequentaram apenas as aulas regulares.

Os vetores de notas obtidos foram:

- `notas_monitoria` = [8.5, 9.0, 7.5, 8.0, 9.5, 8.5, 7.0, 9.0, 8.0, 8.5, 9.5, 7.0]
- `notas_regular` = [7.0, 6.5, 8.0, 7.5, 6.0, 7.0, 8.5, 6.5, 7.5, 8.0, 6.0, 7.0, 6.5, 7.5, 6.0]

O professor deseja testar se a diferença observada entre as notas médias dos dois grupos pode ser explicada por puro acaso (variabilidade amostral) ou se há evidências estatísticas significativas de que o programa de monitoria causou uma melhoria nas notas.

Atividades Práticas

Escreva um script Python modularizado (no arquivo `pratica_permutacao.py`) que realize as seguintes etapas e responda às questões no relatório LaTeX correspondente:

Tarefa 1 Cálculo Estatístico Inicial: Calcule e exiba as médias amostrais de cada grupo ($\bar{X}_{\text{monitoria}}$ e $\bar{X}_{\text{regular}}$) e a estatística de teste observada ($\text{Observed_Diff} = \bar{X}_{\text{monitoria}} - \bar{X}_{\text{regular}}$).

Tarefa 2 Formulação de Hipóteses: Formule detalhadamente a Hipótese Nula (H_0) e a Hipótese Alternativa (H_1) para este problema. Explique se o teste adequado para avaliar a eficácia do programa deve ser unilateral (cauda direita) ou bicaudal.

Tarefa 3 Simulação sob H_0 (Embaralhamento): Implemente o algoritmo do Teste de Permutação. Para isso:

- Agrupe todas as 27 notas em um único vetor do NumPy.
- Realize 10.000 repetições de embaralhamento sem reposição usando `np.random.permutation`.
- Em cada iteração, divida os dados simulados em dois grupos fictícios de tamanhos 12 e 15, e armazene a diferença entre suas médias em um vetor `diferencas_simuladas`.

Tarefa 4 Cálculo do P -valor Empírico: Calcule o p -valor empírico unilateral sob a distribuição simulada. Explique teoricamente o significado do p -valor obtido neste contexto.

Tarefa 5 Visualização dos Resultados: Gere um histograma com a distribuição empírica das diferenças simuladas. Adicione:

- Uma linha vertical tracejada vermelha no valor da diferença observada.
- Destaque na cor dourada (`#ff9900`) a cauda do histograma que representa as diferenças iguais ou maiores que a observada.
- Remova as bordas superior e direita do gráfico utilizando uma função de limpeza visual (`despine`).
- Salve a imagem como `histograma_notas.png`.

Tarefa 6 Tomada de Decisão: Considerando o nível de significância de $\alpha = 5\%$, você rejeita a hipótese nula H_0 ? Escreva uma conclusão formal a ser apresentada à coordenação de curso sobre a viabilidade do programa de monitoria.

Gabarito Comentado e Código de Referência

Gabarito das Tarefas Teóricas

Resolução das Hipóteses (Tarefa 2):

- H_0 : A distribuição das notas dos alunos que fizeram monitoria é idêntica à dos que não fizeram ($H_0 : \mu_{\text{monitoria}} = \mu_{\text{regular}}$). O programa de monitoria não tem efeito.
- H_1 : A distribuição de notas do grupo monitoria apresenta média sistematicamente maior do que a do grupo regular ($H_1 : \mu_{\text{monitoria}} > \mu_{\text{regular}}$).
- **Tipo de Teste:** Como a monitoria é desenhada para melhorar o rendimento, estamos interessados apenas em detectar se as notas aumentaram. O teste adequado é unilateral (cauda direita).

Decisão Estatística (Tarefa 6):

- Diferença Observada: 1.3000 pontos.
- P-valor Empírico: 0.0007 (0.07%).
- **Conclusão:** Como o p -valor (0.07%) é consideravelmente menor que $\alpha = 5\%$, rejeitamos categoricamente H_0 . Há fortes evidências de que a participação na monitoria causou uma melhoria nas notas. Recomenda-se a continuidade do programa.

Script Python de Referência

```
import numpy as np
import matplotlib.pyplot as plots

# Estilo visual limpo
plots.style.use('seaborn-v0_8-colorblind')
plots.rcParams.update({
    'figure.figsize': (10, 6),
    'axes.labelsize': 12,
    'axes.titlesize': 14,
    'lines.linewidth': 2.5
})

def despine(ax):
    ax.spines['top'].set_visible(False)
    ax.spines['right'].set_visible(False)

# Dados originais
notas_monitoria = np.array([8.5, 9.0, 7.5, 8.0, 9.5, 8.5, 7.0, 9.0,
                             8.0, 8.5, 9.5, 7.0])
notas_regular = np.array([7.0, 6.5, 8.0, 7.5, 6.0, 7.0, 8.5, 6.5,
                           7.5, 8.0, 6.0, 7.0, 6.5, 7.5, 6.0])
```

```

# Tarefa 1: Estatísticas observadas
media_mon = np.mean(notas_monitoria)
media_reg = np.mean(notas_regular)
obs_diff = media_mon - media_reg
print(f"Media Monitoria: {media_mon:.4f}")
print(f"Media Regular: {media_reg:.4f}")
print(f"Diferenca Observada: {obs_diff:.4f}")

# Tarefa 3: Simulacao
todas_notas = np.concatenate([notas_monitoria, notas_regular])
N_mon = len(notas_monitoria)
repeticoes = 10000

np.random.seed(42)
diferencas_simuladas = np.zeros(repeticoes)

for i in range(repeticoes):
    embaralhado = np.random.permutation(todas_notas)
    sim_mon = embaralhado[:N_mon]
    sim_reg = embaralhado[N_mon:]
    diferencas_simuladas[i] = np.mean(sim_mon) - np.mean(sim_reg)

# Tarefa 4: P-valor
p_valor = np.count_nonzero(diferencas_simuladas >= obs_diff) /
    repeticoes
print(f"P-valor empirico: {p_valor:.5f}")

# Tarefa 5: Visualizacao
fig, ax = plots.subplots()
bins = np.arange(-2.0, 2.1, 0.2)
n, bins_out, patches = ax.hist(diferencas_simuladas, bins=bins,
    edgecolor='white', color='#2c3e50', density=True, label='Sob a
    Hipotese Nula')

# Destacar a cauda
for patch in patches:
    if (patch.get_x() + patch.get_width()) > obs_diff:
        patch.set_facecolor('#ff9900')

ax.axvline(obs_diff, color='#e74c3c', linestyle='dashed', linewidth
    =3, label=f'Diferenca Obs. ({obs_diff:.2f})')

from matplotlib.patches import Patch
legenda_patches = [
    Patch(facecolor='#2c3e50', edgecolor='white', label='Diferencas
        sob H0'),
    Patch(facecolor='#ff9900', label='Diferenca >= Observada (P-
        valor)'),
    ax.lines[0]
]

```

```
ax.legend(handles=legenda_patches)
ax.set_title('Distribuicao Nula de Diferenca de Notas vs. Observado
')
ax.set_xlabel('Diferenca de Medias (Monitoria - Regular)')
ax.set_ylabel('Densidade')

despine(ax)
plots.tight_layout()
plots.savefig('histograma_notas.png', dpi=150)
plots.close()
print("Grafico histograma_notas.png salvo!")
```