

Testes de Hipótese e Permutação

Ciência de Dados e Decisão

Prof. Reginaldo Fernandes
Adaptação Didática

Instituto Federal do Ceará – Campus Tauá
Tecnologia em Análise e Desenvolvimento de Sistemas

3 de agosto de 2026

Sumario da Aula

- 1 Introdução e Estudo de Caso (Swain vs. Alabama)
- 2 Formalização e o Modelo de Mendel
- 3 Múltiplas Categorias e TVD (Alameda County)
- 4 Testes A/B e Permutação
- 5 Limites de Significância e Erros de Decisão

O Problema da Decisão com Dados

Pergunta Fundamental

Como avaliar se uma discrepância observada em nossos dados é real (sinal sistemático) ou se é apenas fruto da variabilidade natural do acaso (ruído aleatório)?

Exemplos Anteriores

- Eficácia de vacinas em ensaios clínicos.
- Probabilidade em lançamentos de moedas.
- Diferença de peso de recém-nascidos.

Hoje exploraremos uma abordagem computacional robusta baseada em simulação e reamostragem para responder a essa pergunta de forma intuitiva.

Estudo de Caso: Robert Swain vs. Alabama (1962)

O Contexto Histórico

Em 1962, Robert Swain, um homem negro, foi condenado à morte no Alabama. Ele apelou da sentença apontando que o júri era inteiramente branco e denunciou discriminação racial sistemática no processo de seleção.

Dados Demográficos do Caso:

- População de jurados elegíveis: 26% negros.
- Painel de pré-seleção (N): 100 homens.
- Quantidade de negros no painel (X): apenas 8 (8%).
- Júri final da condenação: 0 negros.

A Suprema Corte americana negou o apelo afirmando que a discrepância era pequena.

Relembrando: Intervalo de Confiança Clássico (TCL)

Parâmetros da Amostra

- $N = 100$ jurados.
- $p = 0.08$ (8% negros).

Variância de Bernoulli

$X_i \in \{0, 1\}$ (V.A. de Bernoulli):

- Média ($\bar{X}$) = $p = 0.08$
- Variância (s^2) = $p(1 - p) = 0.0736$
- Erro Padrão (SE) =
$$\sqrt{\frac{p(1-p)}{N}} \approx 0.0271$$

Cálculo do $IC_{95\%}$ via TCL

$$IC_{95\%} = p \pm z \times SE$$

$$IC_{95\%} = 0.08 \pm 1.96 \times 0.0271$$

$$IC_{95\%} = 0.08 \pm 0.0531$$

$$IC_{95\%} = [2.69\%; 13.31\%]$$

A proporção esperada de 26% está completamente fora do intervalo!

Relembrando: Intervalo de Confiança via Bootstrap

Abordagem de Reamostragem (Bootstrap)

Se não quisermos assumir a aproximação normal do TCL, podemos reamostrar com reposição a partir da própria amostra original de 100 pessoas (8 negros e 92 brancos).

```
import numpy as np

# Amostra original: 1 para negro, 0 para branco
amostra = np.array([1]*8 + [0]*92)

# Gera 10.000 amostras Bootstrap de tamanho 100 com reposicao
np.random.seed(42)
medias_boot = [np.random.choice(amostra, size=100).mean() for _ in range(10000)]

# Intervalo de Confiança de 95% (Percentis 2.5% e 97.5%)
ic_inf = np.percentile(medias_boot, 2.5)
ic_sup = np.percentile(medias_boot, 97.5)
print(f"IC 95% Bootstrap: [{ic_inf:.4f}; {ic_sup:.4f}]")
# Saída: [0.0300; 0.1400] (ou [3.0%; 14.0%])
```

Novamente, a proporção esperada de 26% está fora do intervalo!

Modelando o Acaso (Modelo Nulo)

Definição de Modelo Nulo

É uma suposição básica de que não há efeito sistemático; qualquer diferença observada é puro fruto do acaso. Conseguimos programar computacionalmente esse modelo.

Nosso Exemplo:

Cada pessoa do painel é selecionada de forma independente, com probabilidade constante $\mu = 0.26$ de ser negra. O júri é uma amostra de tamanho $N = 100$.

A Pergunta Estatística

Qual a probabilidade de selecionar 8 ou menos homens negros em um painel aleatório de 100 pessoas, quando a proporção real na população é de 26%?

Construindo o Modelo Simulado: População

Ideia de Simulação Física

Para comparar nossos dados com o modelo aleatório, podemos simular toda a população do município em um vetor.

- Definimos uma população grande (ex: 10.000 pessoas).
- Seta todos para "W" (Branco).
- Seta os primeiros 26% para "B" (Negro), representando a hipótese nula H_0 .

```
import numpy as np
pop_total = 10000
prop_negros = 0.26

# Cria o vetor da populacao e seta todos para 'W'
populacao = np.zeros(shape=pop_total, dtype='c')
populacao[:] = 'W'

# Seta os primeiros 26% para 'B'
populacao[:int(pop_total * prop_negros)] = 'B'
```

Note que essa simulação é conceitualmente a mesma coisa do Bootstrap, mas aqui simulamos a população!

Como Simular o Sorteio do Júri?

Algoritmo de Simulação por Embaralhamento

Para simular a seleção justa de um júri de 100 pessoas:

- 1 Embaralhe a população aleatoriamente.
- 2 Selecione os primeiros 100 elementos como o júri.
- 3 Conte e guarde o número de negros.
- 4 Repita o processo 10.000 vezes.

```
juri_tamanho = 100
repeticoes = 10000
simulacoes = np.zeros(repeticoes)

for i in range(repeticoes):
    np.random.shuffle(populacao)
    juri = populacao[:juri_tamanho]
    num_negros = (juri == b'B').sum()
    simulacoes[i] = num_negros
```

Embora muito visual, este método é lento. Usamos a distribuição Binomial para simular o mesmo processo de forma otimizada!

Abordagem Computacional: Simulação Monte Carlo

```
import numpy as np


# Proporcao populacional de negros (Hipotese Nula)
prob_negros = 0.26
tamanho_painel = 100
repeticoes = 10000

# Simula 10000 paineis usando a distribuicao Binomial
np.random.seed(42)
simulacoes = np.random.binomial(n=tamanho_painel, p=prob_negros, size=repeticoes)

# Calcula a proporcao de paineis com 8 ou menos negros
p_valor = np.count_nonzero(simulacoes <= 8) / repeticoes
print(f"P-valor simulado: {p_valor:.6f}")
# Saida esperada: 0.000000
```

Análise do Histograma:

- Os valores simulados sob a hipótese nula variam em torno de 26.
- Em 10.000 simulações, o menor valor gerado foi acima de 12.
- O valor observado de 8 negros é extremamente raro (probabilidade praticamente zero).
- **Decisão:** Rejeitamos o modelo de seleção justa.



Definindo as Hipóteses

Hipótese Nula (H_0)

Afirma que a variação observada nos dados é apenas fruto do acaso e não de uma causa sistemática. Sob essa hipótese, conseguimos simular computacionalmente a geração dos dados.

Hipótese Alternativa (H_1)

Afirma que há um fator sistemático que gerou o desvio dos dados. A variação não pode ser explicada apenas pelo acaso.

Estatística de Teste

É a métrica quantitativa usada para avaliar quão longe os dados observados estão daquilo que é previsto pela hipótese nula H_0 .

Entendendo o P-Valor (Valor de Probabilidade)

Definição Oficial

P-valor é a probabilidade de observar um valor de estatística de teste tão extremo ou mais extremo do que o observado, sob a premissa de que a Hipótese Nula H_0 é verdadeira.

Erros Comuns de Interpretação

- **NÃO É** a probabilidade de a hipótese nula ser verdadeira.
- **NÃO É** a probabilidade de a hipótese alternativa ser falsa.
- É apenas um medidor de surpresa sob a hipótese nula.

Mendel e a Hereditariedade das Plantas

Gregor Mendel propôs que em cruzamentos híbridos, a planta tinha 75% de chance de ter flores roxas e 25% de ter flores brancas.

Os Dados Observados:

- Tamanho da amostra (N): 929 plantas.
- Plantas de flor roxa: 705 ($\approx 75.89\%$).
- Desvio observado: 0.89%.

Será que o desvio de 0.89% da previsão de 75% é sinal de falha do modelo de Mendel ou apenas ruído amostral?

Estatística de Teste: Distância Absoluta

Como há apenas duas categorias, a estatística de teste ideal é a diferença absoluta entre o percentual observado e 75%:

$$\text{Estatística} = |\text{Percentual de Flores Roxas} - 75|$$

Cálculo do Valor Observado

$$\text{Percentual Observado} = \frac{705}{929} \times 100 \approx 75.888\%$$

$$\text{Estatística Observada} = |75.888 - 75| = 0.888\%$$

Abordagem Computacional: Mendel

```
import numpy as np


tamanho_amostra = 929
prob_roxa = 0.75
repeticoes = 10000

# Simula 10000 experimentos sob a hipotese nula
np.random.seed(42)
simulados = np.random.binomial(n=tamanho_amostra, p=prob_roxa, size=repeticoes)
percents_simulados = (simulados / tamanho_amostra) * 100
estatisticas_sim = np.abs(percents_simulados - 75.0)

# Calcula o P-valor
obs_dist = np.abs((705 / tamanho_amostra) * 100 - 75.0)
p_valor = np.count_nonzero(estatisticas_sim >= obs_dist) / repeticoes
print(f"P-valor: {p_valor:.4f}")
# Saida aproximada: 0.5418
```


Análise do Resultado:

- O desvio de 0.888% ou maior ocorre em mais de 54% das simulações aleatórias.
- O desvio observado é comum no mundo nulo.
- **Decisão:** Não rejeitamos a hipótese nula H_0 . O modelo de Mendel é consistente com os dados.




Desafio de Múltiplas Categorias: Os Dados

O Caso Alameda County (ACLU, 2010)

A ACLU avaliou o júri de 11 processos criminais (1453 pessoas no painel). É preciso determinar se a composição racial difere da população de forma sistemática.

Etnia	Elegível	Painel
Asiático	0.15	0.26
Negro	0.18	0.08
Branco	0.54	0.54
Hispânico	0.12	0.08
Outro	0.01	0.04

Tabela: Distribuição étnica



E se a Amostra Fosse Realmente Aleatória?


Simulação de Seleção Justa (Amostra Multinomial)

Se o sorteio do júri de 1453 pessoas fosse verdadeiramente aleatório e representativo, as proporções da amostra seriam muito próximas das proporções da população.

Etnia	Elegível	Aleatória
Asiático	0.15	0.14
Negro	0.18	0.18
Branco	0.54	0.56
Hispânico	0.12	0.11
Outro	0.01	0.01

Tabela: Amostra aleatória simulada

TVD simulado: 0.0178 (1.78%)



Matemática da Distância de Variação Total (*TVD*)

Métrica de Distância de Variação Total (*TVD*)

Usada para comparar duas distribuições categóricas. É definida como metade da soma das diferenças absolutas entre as proporções de cada categoria:

$$TVD = \frac{1}{2} \sum_{i=1}^k |p_i - q_i|$$

Onde p_i é a proporção amostral e q_i é a proporção esperada.

Exemplo de Cálculo para Alameda County:

$$TVD_{\text{obs}} = \frac{1}{2} \left(|0.26 - 0.15| + |0.08 - 0.18| + |0.54 - 0.54| + \right. \\ \left. |0.08 - 0.12| + |0.04 - 0.01| \right)$$

$$TVD_{\text{obs}} = \frac{1}{2} (0.11 + 0.10 + 0.00 + 0.04 + 0.03) = \frac{0.28}{2} = 0.14$$

Abordagem Computacional: TVD

```
import numpy as np


prop_elegivel = np.array([0.15, 0.18, 0.54, 0.12, 0.01])
prop_painel = np.array([0.26, 0.08, 0.54, 0.08, 0.04])
obs_tvd = 0.5 * np.sum(np.abs(prop_painel - prop_elegivel))

tvds = []
np.random.seed(42)
for _ in range(10000):
    # Sorteia 1453 jurados de acordo com a distribuicao populacional
    amostra = np.random.multinomial(1453, prop_elegivel)
    prop_sim = amostra / 1453
    tvd_sim = 0.5 * np.sum(np.abs(prop_sim - prop_elegivel))
    tvds.append(tvd_sim)

# Calcula o P-valor
p_valor = np.count_nonzero(tvds >= obs_tvd) / 10000
print(f"P-valor: {p_valor}")
# Saida esperada: 0.0
```

Análise do Gráfico:

- Sob a hipótese nula, o *TVD* máximo gerado em 10.000 repetições foi próximo de 0.05.
- O valor observado de 0.14 está fora da região de variação aceitável do acaso.
- **Decisão:** Rejeitamos a hipótese nula H_0 . O painel de Alameda County não foi selecionado aleatoriamente.



A Lógica da Permutação de Rótulos

Se a hipótese nula H_0 é verdadeira (não há diferença entre o grupo de Tratamento e Controle), a associação entre as variáveis é irrelevante. Logo, podemos embaralhar aleatoriamente os rótulos dos grupos sem alterar a estrutura básica dos dados.

Algoritmo Geral:

- 1 Reúna os dados dos dois grupos em um único vetor.
- 2 Embaralhe aleatoriamente os elementos.
- 3 Separe a primeira amostra com tamanho N_A (grupo A) e a segunda com N_B (grupo B).
- 4 Calcule a diferença de médias.
- 5 Repita o processo 10.000 vezes para criar a distribuição nula.


Caso 1: Tabagismo Materno e Peso do Bebê

Pergunta Científica

O tabagismo de gestantes afeta o peso do recém-nascido?

Detalhes dos Grupos:

- Grupo A (Fumantes): 459 bebês.
- Grupo B (Não Fumantes): 715 bebês.
- Estatística: $\bar{X}_B - \bar{X}_A$
- Diferença de médias observada: 0.26 kg.



Código em Python: Permutação de Peso de Bebês

```
import numpy as np

conjunto = np.concatenate([grupo_fumantes, grupo_nao_fumantes])
n_a = len(grupo_fumantes)
diferencas = []
np.random.seed(42)

for _ in range(10000):
    # Embaralha os pesos de todos os bebês
    embaralhado = np.random.permutation(conjunto)
    sim_a = embaralhado[:n_a]
    sim_b = embaralhado[n_a:]
    diferencas.append(np.mean(sim_b) - np.mean(sim_a))

# Calcula o P-valor
p_valor = np.count_nonzero(diferencas >= 0.26) / 10000
print(f"P-valor: {p_valor:.4f}")
# Saida: 0.0000
```

O que significa “ser mais extremo”?

Dependendo de como definimos a nossa **Hipótese Alternativa (H_1)**, medimos o desvio em caudas diferentes da distribuição:

- ❶ **Unilateral (Cauda Direita):** $Média_{\text{Não-Fumante}} > Média_{\text{Fumante}}$
 - Buscamos proporção de valores simulados ≥ 0.26 kg.
- ❷ **Unilateral (Cauda Esquerda):** $Média_{\text{Não-Fumante}} < Média_{\text{Fumante}}$
 - Buscamos proporção de valores simulados ≤ 0.26 kg.
- ❸ **Bicaudal (Duas Caudas):** $Média_{\text{Não-Fumante}} \neq Média_{\text{Fumante}}$
 - Buscamos proporção de valores em módulo $|\text{simulado}| \geq 0.26$ kg.

Cada alternativa altera a área (cauda) que calculamos para obter o P-valor.

Resultado Obtido

- Diferença de médias observada na amostra real: 0.26 kg.
- Em 10.000 embaralhamentos (permutações) simulados sob a hipótese nula H_0 , a diferença de médias nunca alcançou 0.26 kg.
- Nosso p -valor empírico foi de 0.0000 (0%).

Tomada de Decisão

Como p -valor (0%) < Limiar de Significância ($\alpha = 5\%$), **rejeitamos a hipótese nula H_0 .**

Conclusão: O tabagismo na gestação está estatisticamente associado a uma redução sistemática no peso do recém-nascido. A diferença não é explicável pelo acaso.

Caso 2: Salários NBA (Cleveland vs. Houston)

O Problema de Variância

Cleveland Cavs e Houston Rockets têm salários médios aparentando diferença (10.23 M\$ vs 7.10 M\$ na população). Porém, a variância de salários na NBA é extremamente alta e a amostra de jogadores disponível é muito pequena ($N = 15$ por time).

Amostra Simulada ($N = 15$)

Para ilustrar o teste computacionalmente, geramos uma amostra sintética de 15 jogadores por time:

- Média Cleveland na Amostra: 10.34 M\$
- Média Houston na Amostra: 2.85 M\$
- Diferença Observada na Amostra: 7.50 M\$

Será que uma diferença aparente de 7.50 M\$ é significativa ou pode ser explicada apenas pela variabilidade natural dos salários?

Resultados de Permutações nos Salários

Médias de Cleveland e Houston após o Shuffle

Sob a hipótese nula H_0 , a designação do time é mero rótulo. Ao misturar todos os salários e sortear-los em dois grupos de 15, veja como as médias variam por puro acaso:

Rodada (Shuffle)	Média Cleveland	Média Houston	Diferença ($C - H$)
Amostra Real Simulada	10.34 M\$	2.85 M\$	7.50 M\$
Simulação 1	7.92 M\$	5.27 M\$	2.64 M\$
Simulação 2	4.79 M\$	8.40 M\$	-3.61 M\$
Simulação 3	9.13 M\$	4.06 M\$	5.08 M\$
Simulação 4	5.23 M\$	7.96 M\$	-2.74 M\$

Tabela: Exemplos de médias e diferenças após permutações

Note que mesmo no modelo nulo (sem efeito real), as diferenças flutuam bastante devido à alta variabilidade dos dados.

Código em Python: Salários da NBA

```
import numpy as np

conjunto = np.concatenate([grupo_houston, grupo_cleveland])
n_a = len(grupo_houston)
diferencas_nba = []
np.random.seed(42)


for _ in range(10000):
    # Embaralha os salarios dos jogadores
    embaralhado = np.random.permutation(conjunto)
    sim_a = embaralhado[:n_a]
    sim_b = embaralhado[n_a:]
    diferencas_nba.append(np.mean(sim_b) - np.mean(sim_a))

# Teste bicaudal para o P-valor
obs_diff = 7.50
p_valor = np.count_nonzero(np.abs(diferencas_nba) >= np.abs(obs_diff)) / 10000
print(f"P-valor bicaudal: {p_valor:.4f}")
# Saída: 0.1010
```

Análise do P-valor Bicaudal:

- Diferença de médias na amostra: 7.50 M\$.
- P-valor bicaudal: 10.10%.
- Como $p\text{-valor} \geq 5\%$, **não rejeitamos a hipótese nula H_0** .

Conclusão: A diferença observada nos salários não é estatisticamente significativa; a alta variação salarial combinada com a amostra pequena torna a diferença explicável pelo acaso.



O Limiar de Significância e Sir Ronald Fisher

A Convenção de 5%

Sir Ronald Fisher publicou em 1925 que o limiar de 5% ($\alpha = 0.05$) é conveniente para julgar se um desvio deve ou não ser considerado significativo.

Cuidado com o Limiar

- Trata-se de uma convenção histórica, não uma verdade matemática absoluta.
- Em conjuntos de dados muito grandes, é recomendável buscar limites muito menores (ex: 0.01 ou 0.001) para evitar falsos positivos.
- Cuidado com a prática do “P-hacking” (manipulação de dados até atingir o $p < 0.05$).

Erros de Decisão Estatística

Erro do Tipo I (Falso Positivo)

Ocorre quando rejeitamos a Hipótese Nula H_0 , embora ela seja verdadeira. A probabilidade máxima de cometer esse erro é igual ao nível de significância α .

Erro do Tipo II (Falso Negativo)

Ocorre quando falhamos em rejeitar a Hipótese Nula H_0 , embora a Hipótese Alternativa H_1 seja verdadeira. A probabilidade desse erro é representada por β .

Poder do Teste

Representado por $1 - \beta$, é a capacidade do teste estatístico de detectar um sinal real quando ele realmente existe.

Matriz de Decisão Estatística

Realidade	Decisão: Não Rejeitar H_0	Decisão: Rejeitar H_0
H_0 é Verdadeira	Decisão Correta	Erro Tipo I (α Falso Positivo)
H_1 é Verdadeira	Erro Tipo II (β Falso Negativo)	Decisão Correta (Poder: $1 - \beta$)

Tabela: Matriz de decisão e probabilidades de erro

Existe um compromisso entre α e β : diminuir a tolerância a falsos positivos (α) tipicamente reduz o poder do teste, aumentando os falsos negativos (β).

Pontos-Chave da Aula

- **Modelo Nulo:** O modelo do acaso no qual conseguimos realizar simulações computacionais.
- **TVD:** Estatística de teste robusta para comparar distribuições com múltiplas categorias.
- **Teste de Permutação:** Método de reamostragem ideal para Testes A/B, pois não exige premissas distributivas.
- **P-Valor:** Mede a compatibilidade entre a amostra observada e o modelo nulo.

Dica: Sempre comece definindo com clareza a Hipótese Nula (H_0) e a Estatística de Teste apropriada!

Leituras Recomendadas

- **Learning Data Science**

Sam Lau, Joey Gonzalez, and Deb Nolan.

Capítulo 17: Inference, Prediction, and Generalization.

https://learningds.org/ch/17/inf_pred_gen_HT.html

- **Computational and Inferential Thinking**

Ani Adhikari and John DeNero.

Capítulo 11: Testing Hypotheses.

<https://inferentialthinking.com/chapters/11/testing-hypotheses/>