

Correlação Linear e Associação

Teoria, Computação e Tomada de Decisão Visual

Tecnologia em Análise e Desenvolvimento de Sistemas
Ciência de Dados / Estatística Computacional

Instituto Federal do Ceará – Campus Tauá

18 de agosto de 2026

Sumário da Aula

1 Covariância e Coeficiente de Pearson

2 Limitações, Spearman e Simpson

Qual Problema de Ciência de Dados?

- **Objetivo:** Mensurar o efeito de uma variável preditora X na variável resposta Y .
- Em aulas anteriores, vimos abordagens baseadas em testes de hipóteses:
 - Qual o efeito do hábito de fumar no peso dos bebês? $\implies$ **Negativo**.
 - Qual o efeito de uma vacina na incidência de uma doença? $\implies$ **Ainda não sabemos**.
 - Qual o efeito da escalação de um time no salário dos jogadores? $\implies$ **Sem significância estatística**.
- **Nova Abordagem:** Responderemos a essas mesmas perguntas quantitativas via modelagem e regressão!

Variável Preditora (X) $\longrightarrow$ Variável Resposta (Y)

Caso Real: Veículos Híbridos


- Quais correlações seria interessante observar neste conjunto de dados?
- Quais relações seriam potencialmente causais?

Modelo	Ano	Preço (mil USD)	Acc (s)	Consumo (mpg)	Classe
Prius (1ª Ger)	1997	24,51	7,46	41,26	Compacto
Tino	2000	35,35	8,20	54,10	Compacto
Prius (2ª Ger)	2000	26,83	7,97	45,23	Compacto
Insight	2000	18,94	9,52	53,00	Dois Lugares
Civic (1ª Ger)	2001	25,83	7,04	47,04	Compacto

Correlação: Aceleração vs. Preço

Aceleração e Preço:


- Para observar uma correlação, fazemos uso de um **Gráfico de Dispersão** (Scatter Plot).
- Observa-se uma relação positiva entre a aceleração (segundos para 0-100 km/h) e o preço sugerido do veículo (MSRP).
- Veículos com maior tempo de aceleração (geralmente mais potentes/pesados) têm preço sugerido de varejo superior.



Correlação: Consumo vs. Aceleração

Consumo e Desempenho:

- Relação negativa evidente entre o consumo (milhas por galão - mpg) e a aceleração (segundos).
- O comportamento dos dados sugere uma tendência não-linear.
- Veículos mais eficientes e econômicos (alto mpg) exigem maior tempo de aceleração.



Lembrando da Variância Amostral

- A **Variância Amostral** (s^2) sumariza a dispersão de apenas uma variável quantitativa:

$$s^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N - 1}$$

- Onde:
 - N é o **Tamanho da Amostra**.
 - $\bar{X}$ é a **Média Amostral**.
 - x_i representa cada observação individual.
- **Desafio:** Como podemos proceder para analisar dados bidimensionais (X, Y)?
- **Ideia:** Avaliar a dispersão conjunta das duas variáveis.

Quadrantes de Dispersão

- Ao traçar retas nos pontos correspondentes às médias amostrais $\bar{X}$ e $\bar{Y}$, dividimos o plano em quatro quadrantes.
- Concentração de pontos nos quadrantes 1 e 3 indica associação positiva.
- Concentração de pontos nos quadrantes 2 e 4 indica associação negativa.

Quadrantes em Torno da Média

Quadrante 2 $(x_i - \bar{X}) < 0$ $(y_i - \bar{Y}) > 0$ Produto: Negativo	Quadrante 1 $(x_i - \bar{X}) > 0$ $(y_i - \bar{Y}) > 0$ Produto: Positivo
Quadrante 3 $(x_i - \bar{X}) < 0$ $(y_i - \bar{Y}) < 0$ Produto: Positivo	Quadrante 4 $(x_i - \bar{X}) > 0$ $(y_i - \bar{Y}) < 0$ Produto: Negativo

A Covariância Amostral

- Definimos a **Covariância Amostral** ($cov(X, Y)$) como a média dos produtos dos desvios:

$$cov(X, Y) = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{N - 1}$$

- Propriedades do Sinal:**

- Se $cov(X, Y) > 0$: Associação positiva (pontos nos quadrantes 1 e 3 dominam).
 - Se $cov(X, Y) < 0$: Associação negativa (pontos nos quadrantes 2 e 4 dominam).
 - Se $cov(X, Y) \approx 0$: Ausência de associação linear.
- Problema Crucial:** A unidade de medida da covariância é o produto das unidades dos dados originais (ex: $kg \cdot metros$), dificultando julgar a força da associação.

O Coeficiente de Correlação de Pearson (r)

- Para resolver o problema de unidade, dividimos a covariância pelo produto dos desvios padrões amostrais (s_x, s_y):



$$r = \frac{\text{cov}(X, Y)}{s_x \cdot s_y} = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{X})^2 \sum_{i=1}^N (y_i - \bar{Y})^2}}$$

- **Características de r :**

- É uma grandeza adimensional (sem unidade de medida).
- Está limitado estritamente ao intervalo: $-1 \leq r \leq 1$.
- $r = 1$: Relação linear positiva perfeita.
- $r = -1$: Relação linear negativa perfeita.
- $r = 0$: Sem correlação linear.

Covariância vs. Correlação: Comparação Prática


- A **Covariância Amostral** ($cov(X, Y)$) é sensível à escala física de cada variável.
- O **Coefficiente de Correlação de Pearson** (r) normaliza essa relação, permitindo comparar diretamente o grau de associação linear de diferentes variáveis.



Exploração Multivariada: Plot de Pares

Visualização Integrada:

- O **Plot de Pares** (Pair Plot) combina histogramas marginais na diagonal com gráficos de dispersão bivariados fora dela.
- Permite ao analista identificar padrões lineares, não-lineares e outliers em todas as variáveis simultaneamente.
- Indispensável nas etapas iniciais de exploração de dados.



Exemplo Pareado: Passo Teórico (1/2)

Vamos calcular manualmente o coeficiente r para o conjunto de pontos:

Dados: $(1, 2), (2, 4), (3, 5), (4, 4), (5, 5)$

1 Médias Amostras:

$$\bar{X} = \frac{1 + 2 + 3 + 4 + 5}{5} = 3.0, \quad \bar{Y} = \frac{2 + 4 + 5 + 4 + 5}{5} = 4.0$$

2 Desvios e Produtos:

- $X - \bar{X} = [-2, -1, 0, 1, 2]$
- $Y - \bar{Y} = [-2, 0, 1, 0, 1]$
- Produtos dos desvios: $[4, 0, 0, 0, 2] \implies \sum = 6.0$

3 Covariância Amostral:

$$\text{cov}(X, Y) = \frac{6.0}{5 - 1} = 1.5$$

Exemplo Pareado: Passo Teórico (2/2)

Dados: (1, 2), (2, 4), (3, 5), (4, 4), (5, 5)

4 Variâncias e Desvios Padrão Amostrais:

$$s_x^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{4} = 2.5 \implies s_x = \sqrt{2.5} \approx 1.5811$$

$$s_y^2 = \frac{(-2)^2 + 0^2 + 1^2 + 0^2 + 1^2}{4} = 1.5 \implies s_y = \sqrt{1.5} \approx 1.2247$$

5 Coeficiente de Correlação de Pearson (r):

$$r = \frac{\text{cov}(X, Y)}{s_x \cdot s_y} = \frac{1.5}{1.5811 \cdot 1.2247} = \frac{1.5}{1.9365} \approx \mathbf{0.7746}$$

O resultado aponta uma associação linear positiva de moderada a forte.

Exemplo Pareado: Demonstração Computacional

Cálculo em Python equivalente

```
import numpy as np
from scipy import stats

# Dados do exemplo teorico
x = np.array([1, 2, 3, 4, 5])
y = np.array([2, 4, 5, 4, 5])

# Calculo usando numpy (matriz de covariancia)
# ddof=1 garante o denominador N-1 da covariancia amostral
cov_mat = np.cov(x, y, ddof=1)
cov_xy = cov_mat[0, 1]

# Calculo de Pearson
r, p_valor = stats.pearsonr(x, y)

print(f"Covariancia Amostral: {cov_xy:.4f}")
print(f"Pearson r: {r:.4f}")
# Saída esperada:
# Covariancia Amostral: 1.5000
# Pearson r: 0.7746
```

- **Invariância por Escala e Translação:**

- Somar ou subtrair constantes aos dados não altera r .
- Multiplicar os dados por uma constante positiva não altera r .
- $\implies$ a correlação independe das unidades físicas de medida utilizadas.

- **Simetria:** A correlação entre X e Y é idêntica à de Y e X ($r_{XY} = r_{YX}$).

- **Interpretação Geométrica:**

- O r de Pearson equivale ao cosseno do ângulo θ entre os vetores de desvios normalizados:

$$r = \cos(\theta)$$

- Vetores ortogonais ($\theta = 90^\circ$) possuem correlação nula ($r = 0$).
- Vetores na mesma linha ($\theta = 0^\circ$ ou 180°) possuem correlação perfeita ($r = 1$ ou -1).

- **Mede apenas Relações Lineares:**

- Se $Y = X^2$ de forma exata, existe uma relação determinística perfeita.
- Contudo, o cálculo do r de Pearson para um intervalo simétrico em torno de zero (ex: $[-2, 2]$) resultará em $r = 0$.

- **Alta Sensibilidade a Outliers:**

- Um único valor extremo fora do padrão de dispersão geral dos dados pode inflar artificialmente ou reduzir drasticamente o valor de r .

- **Correlações Ecológicas:**

- Tirar conclusões sobre indivíduos com base na correlação de dados agrupados em grandes grupos (ex: média de renda urbana por país vs. taxa de criminalidade).

A Correlação de Postos de Spearman (r_s)

- Quando a relação é não-linear mas ainda preserva uma ordem monotônica (ambas crescem ou decrescem juntas), Pearson falha em medir a intensidade total.
- A alternativa é a **Correlação de Postos de Spearman** (r_s):
 - 1 Ordenamos os dados de X e de Y separadamente.
 - 2 Substituímos cada valor original pelo seu respectivo Posto (ou Posição de ordenação, de 1 a N).
 - 3 Calculamos o Coeficiente de Pearson sobre estes postos ordinais.
- **Vantagens:**
 - Mede qualquer relação monotônica (curvas não-lineares coerentes).
 - Muito mais resistente a valores atípicos extremos (outliers).

Exemplo Pareado: Pearson vs. Spearman

Caso Prático:

- Análise de uma curva exponencial com ruído.
- O ajuste linear clássico é pobre para esta tendência acelerada.

Resultados:


- Pearson $r \approx 0.86$ (subestima a força da associação).
- Spearman $r_s \approx 0.99$ (identifica a relação monotônica quase perfeita).

```
# Código Python para comparar
from scipy import stats
import numpy as np

# Gerar dados exponenciais
x = np.linspace(1, 10, 50)
y = np.exp(x) + np.random.normal(0, 500, size=50)

# Calcular coeficientes
r_p, _ = stats.pearsonr(x, y)
r_s, _ = stats.spearmanr(x, y)

print(f"Pearson: {r_p:.4f}")
print(f"Spearman: {r_s:.4f}")
```




O Paradoxo de Simpson

- Fenômeno no qual uma associação de dados observada em múltiplos subgrupos de forma consistente se **inverte** ou **desaparece** quando os dados são combinados no agregado.
- Ocorre por ignorar variáveis de confusão importantes que controlam os dados (ex: idade, demografia, fatores temporais).
- **Implicação para Tomada de Decisão:**
 - Confiar cegamente em estatísticas globais agregadas pode levar a inferências completamente equivocadas sobre a realidade física.

Estudo de Caso 1: Colesterol vs. Exercício (Agregado)

Aparência Enganosa:


- No agregado geral (todos os dados combinados), a correlação entre exercício e colesterol é positiva ($r \approx 0.35$).
- Isso parece indicar que se exercitar mais aumenta o colesterol!
- **Explicação:** Trata-se de uma associação espúria causada pela omissão de uma variável de confusão (idade).



Estudo de Caso 1: Colesterol vs. Exercício (Estratificado)

A Estratificação Revela:

- Ao agrupar por idade, descobrimos que em todas as faixas (Jovens, Adultos e Idosos) a correlação é negativa ($r \approx -0.58$).
- Pessoas idosas têm colesterol maior e se exercitam menos, o que distorce a análise agregada geral.
- A tomada de decisão correta exige a análise estratificada.



Estudo de Caso 2: Taxa de Letalidade de COVID-19

- Em dados da fase inicial da pandemia de COVID-19:
 - A taxa de letalidade agregada da Itália era significativamente superior à da China.
 - **Paradoxo:** Ao comparar as taxas segregadas por faixas etárias individuais (ex: 20-29, 30-39, etc.), a taxa chinesa era superior ou igual em praticamente todas as faixas!
- **Por que isso ocorreu?**
 - A Itália possui uma proporção muito maior de idosos em sua demografia comparada à China.
 - Como os idosos são mais vulneráveis ao vírus, o grande número de casos em idosos na Itália inflou o indicador geral agregado do país, ocultando a menor taxa interna de letalidade específica por faixa etária.

Associação não é Causalidade

- Uma correlação linear robusta entre duas variáveis quantitativas ($r \approx 0.95$) descreve apenas a força de seu comportamento linear conjunto.
- **NÃO** comprova que a variação de X causa diretamente a variação de Y .
- Exemplos clássicos de correlações espúrias (coincidência temporal):
 - Gasto dos EUA em ciência vs. suicídios por enforcamento.
 - Consumo de queijo por pessoa vs. mortes por se enrolar em lençóis.
- **Regra de Ouro:** Use a correlação para formular hipóteses, mas recorra a experimentos controlados ou análise de variáveis de confusão para estabelecer causalidade.