

Regressão Linear Simples

Da Reta em Unidades Padrão à Inferência Estatística

Tecnologia em Análise e Desenvolvimento de Sistemas
Ciência de Dados / Estatística Computacional

Instituto Federal do Ceará – Campus Tauá

18 de agosto de 2026

Sumário da Aula

1 A Reta de Regressão e a Função de Perda

2 Regressão nas Unidades dos Dados, Diagnósticos e Qualidade

Como Predizer Y a Partir de X ?

Abordagem Local (Média Condicional):

- Agrupamos os dados em janelas verticais estreitas no eixo X .
- Calculamos a média amostral da variável Y para cada janela.
- Funciona bem se houver abundância de dados em todos os intervalos de X .

Abordagem Global (Modelo Linear):

- E se as janelas tiverem poucos dados (esparsa amostragem)?
- Buscamos uma reta global contínua que descreva a tendência geral.
- Esta linha reta é a chamada **Reta de Regressão**.

Reta em Unidades Padrão (Z-Scores)

- Definimos Z-score (unidades padrão) de uma variável como:

$$x_{su} = \frac{x_i - \bar{X}}{s_x}, \quad y_{su} = \frac{y_i - \bar{Y}}{s_y}$$

- Onde $\bar{X}$, $\bar{Y}$ são as **Médias Amostrais** e s_x , s_y são os **Desvios Padrão Amostrais**.
- Em unidades padrão, a reta de regressão assume uma forma extremamente elegante:



$$\hat{y}_{su} = r \cdot x_{su}$$

- Características:
 - Sempre cruza a origem das coordenadas (0,0).
 - A inclinação (slope) da reta é exatamente o **Coeficiente de Correlação de Pearson** (r).

Considere o Gráfico ao Lado

Sintético

- A linha vermelha é a linha de 45 graus.
- Qual é o valor do Coeficiente Angular (β)?



O Efeito de Regressão (Regressão à Média)

- Como $|r| \leq 1$, a inclinação da reta é menor ou igual a 1.
- **Efeito de Regressão:** A estimativa de Y (em unidades padrão) estará sempre mais próxima da média do que o valor observado de X (em unidades padrão).
- **Explicação Física:**
 - Se um indivíduo apresenta uma medida extrema de X (ex: 2 desvios padrões acima da média), sua predição correspondente $\hat{Y}$ será de apenas $2 \cdot r$ desvios padrões acima da média.
 - O fenômeno foi observado por Francis Galton em estudos de hereditariedade (pais muito altos tendem a ter filhos ligeiramente mais baixos que os pais, aproximando-se da média populacional).

Erro de Estimativa e Função de Perda

- Para qualquer reta de predição ajustada, existirá um **Erro de Estimativa** (ou Resíduo) para cada ponto:

$$e_i = y_i - \hat{y}_i$$

- Como mensurar a qualidade de ajuste global do modelo?
- Definimos a **Função de Perda** (Loss Function) como a **Raiz do Erro Quadrático Médio** (RMSE):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

- Onde N representa o **Tamanho da Amostra**.
- Nosso objetivo estatístico é encontrar a reta que minimiza o valor de $RMSE$.

O Método dos Mínimos Quadrados (Least Squares)

- O **Método dos Mínimos Quadrados** consiste em achar os parâmetros da reta que minimizam a soma dos erros quadrados de predição.
- Em unidades padrão, buscamos o slope β_{su} da reta $\hat{y}_{su} = \beta_{su} \cdot x_{su}$ que minimize:

$$L(\beta_{su}) = \frac{1}{N} \sum_{i=1}^N (y_{i,su} - \beta_{su} \cdot x_{i,su})^2$$

- Derivando em relação a β_{su} e igualando a zero, prova-se analiticamente que:

$$\beta_{su} = \frac{1}{N} \sum_{i=1}^N x_{i,su} \cdot y_{i,su} = r$$

- **Conclusão:** A reta de regressão em unidades padrão é a melhor reta no sentido dos mínimos quadrados.

Exemplo Pareado: Otimização Computacional

Minimizando o RMSE numericamente com SciPy

```
import numpy as np
from scipy.optimize import minimize
from scipy import stats

# Dados originais de exemplo
x = np.array([84.2, 88.1, 91.3, 85.0, 93.4])
y = np.array([89.1, 93.2, 94.5, 90.0, 97.2])

# Z-normalizacao (Unidades Padrao)
x_su = (x - np.mean(x)) / np.std(x, ddof=1)
y_su = (y - np.mean(y)) / np.std(y, ddof=1)

# Funcao de perda: RMSE
def calcular_rmse(beta, x_data, y_data):
    pred = beta[0] * x_data
    return np.sqrt(np.mean((y_data - pred) ** 2))

# Minimizacao numerica da perda
chute = [0.0]
res = minimize(calcular_rmse, chute, method='BFGS')
beta_otimizado = res.x[0]
r_analitico, _ = stats.pearsonr(x, y)

print(f"Beta Otimizado (RMSE): {beta_otimizado:.6f}")
print(f"Pearson r (Analitico): {r_analitico:.6f}")
```

A Reta nas Unidades Originais

- Desfazendo a Z-normalização, chegamos à equação clássica da reta:

$$\hat{y} = \beta X + \alpha$$

- Fórmula do Coeficiente Angular (Slope β):**

$$\beta = r \cdot \frac{s_y}{s_x}$$

- Fórmula do Coeficiente Linear (Intercepto α):**

$$\alpha = \bar{Y} - \beta \bar{X}$$

- Interpretação Prática:**

- Slope (β):** Para cada acréscimo de uma unidade física em X , a predição $\hat{Y}$ aumenta em β unidades físicas de Y .
- Intercepto (α):** Representa a predição para Y caso a variável preditora X assumo o valor zero (deve-se tomar cuidado com a extrapolação fora do domínio amostral).

- O **Coeficiente de Determinação** (R^2) indica a proporção da variabilidade da variável resposta Y que é explicada pelo modelo linear:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{Y})^2}$$


- **Propriedades de R^2 :**

- Na regressão linear simples, vale exatamente o quadrado do coeficiente de Pearson ($R^2 = r^2$).
- Varia no intervalo $[0, 1]$ para regressões de mínimos quadrados comuns.
- Exemplo: $R^2 = 0.65 \implies 65\%$ da variação dos dados de Y é capturada pelo comportamento linear em relação a X .

- O **Gráfico de Resíduos** (Residual Plot) é a principal ferramenta de diagnóstico visual. Consiste em plotar os resíduos $e_i = y_i - \hat{y}_i$ contra o preditor x_i .
- **Suposição de Homocedasticidade:** A variabilidade dos resíduos deve ser constante ao longo de todo o eixo X.
- **Padrões Indesejados a Detectar:**
 - 1 **Não-Linearidade:** Resíduos formam curvas (ex: padrão em U). Sugere necessidade de transformações ou modelos não-lineares.
 - 2 **Heterocedasticidade:** Resíduos apresentam-se em forma de funil (dispersão aumenta com X). Afeta a validade das inferências e testes de hipóteses clássicos.


Diagnósticos Visuais: Exemplos Gráficos

1. Homocedástico




Ideal: dispersão dos resíduos é constante.

2. Não-Linear



Curvatura: relação não segue padrão linear.

3. Heterocedástico



Funil: variância aumenta com a variável X.

Diagnósticos Numéricos de Regressão

- **Média dos Resíduos:** Na regressão de mínimos quadrados, a média amostral dos resíduos é matematicamente igual a zero:

$$\bar{e} = \frac{1}{N} \sum_{i=1}^N e_i = 0$$

- **Desvio Padrão dos Resíduos (SD_{res}):** Mede o espalhamento vertical em torno da reta ajustada:

$$SD_{res} = \sqrt{\frac{\sum e_i^2}{N-2}} \approx \sqrt{1-r^2} \cdot s_y$$

- Onde a aproximação teórica é dada pela multiplicação de $\sqrt{1-r^2}$ pelo **Desvio Padrão Amostral** da variável resposta s_y .

Inferência do Slope por Reamostragem (Bootstrap)

- Em conjuntos de dados amostrais, os coeficientes β e α possuem incerteza estatística (erro padrão).
- Como construir um **Intervalo de Confiança (IC)** para o slope β sem fazer suposições estritas de normalidade?
- **Bootstrap de Pares:**
 - 1 Sorteamos com reposição linhas completas da tabela amostral de tamanho N .
 - 2 Ajustamos uma reta para esta nova amostra Bootstrap e guardamos o slope β_{boot} .
 - 3 Repetimos o processo 2000 vezes para gerar a distribuição empírica do slope.
 - 4 Extraímos as posições 2.5% e 97.5% para formar o Intervalo de Confiança de 95%.

Exemplo Real: Comprimento e Cabeça de Gambás

Comparação: Bootstrap vs. Statsmodels

```
import statsmodels.api as sm
import numpy as np

# X = comprimento do corpo (cm), Y = comprimento da cabeça (mm)
# Amostra simulada de 140 gambas
X_sm = sm.add_constant(comprimento_corpo)
modelo = sm.OLS(comprimento_cabeca, X_sm).fit()

print(modelo.summary().tables[1])
# Tabela classica reporta:
# const: coef = 42.6419 | IC 95% = [36.490, 48.794]
# x1:      coef = 0.5743 | IC 95% = [0.504, 0.644]

# Comparacao com Bootstrap de Pares:
# Slope estimado: 0.5743
# IC 95% Bootstrap: [0.5042, 0.6484]
```

Os métodos concordam fortemente, validando o uso de ferramentas de simulação.