

# Regressão Linear Simples

Da Reta em Unidades Padrão à Inferência Estatística

Tecnologia em Análise e Desenvolvimento de Sistemas  
Ciência de Dados / Estatística Computacional

Instituto Federal do Ceará – Campus Tauá  
Tecnologia em Análise e Desenvolvimento de Sistemas

22 de agosto de 2026

# Sumário da Aula

1 A Reta de Regressão e a Função de Perda

2 Regressão nas Unidades dos Dados, Diagnósticos e Qualidade

# Como Predizer $Y$ a Partir de $X$ ?

## Abordagem Local (Média Condicional):

- Agrupamos os dados em janelas verticais estreitas no eixo  $X$ .
- Calculamos a média amostral da variável  $Y$  para cada janela.
- Funciona bem se houver abundância de dados em todos os intervalos de  $X$ .

## Abordagem Global (Modelo Linear):

- E se as janelas tiverem poucos dados (esparsa amostragem)?
- Buscamos uma reta global contínua que descreva a tendência geral.
- Esta linha reta é a chamada **Reta de Regressão**.

# Reta em Unidades Padrão (Z-Scores)

- Definimos Z-score (unidades padrão) de uma variável como:

$$x_{su} = \frac{x_i - \bar{X}}{s_x}, \quad y_{su} = \frac{y_i - \bar{Y}}{s_y}$$

- Onde  $\bar{X}$ ,  $\bar{Y}$  são as **Médias Amostrais** e  $s_x$ ,  $s_y$  são os **Desvios Padrão Amostrais**.
- Em unidades padrão, a reta de regressão assume uma forma extremamente elegante:



$$\hat{y}_{su} = r \cdot x_{su}$$

- Características:
  - Sempre cruza a origem das coordenadas (0,0).
  - A inclinação (slope) da reta é exatamente o **Coeficiente de Correlação de Pearson** ( $r$ ).

# Considere o Gráfico ao Lado

## Sintético

- A linha vermelha é a linha de 45 graus.
- Qual é o valor do Coeficiente Angular ( $\beta$ )?



# O Efeito de Regressão (Regressão à Média)

- Como  $|r| \leq 1$ , a inclinação da reta é menor ou igual a 1.
- **Efeito de Regressão:** A estimativa de  $Y$  (em unidades padrão) estará sempre mais próxima da média do que o valor observado de  $X$  (em unidades padrão).
- **Explicação Física:**
  - Se um indivíduo apresenta uma medida extrema de  $X$  (ex: 2 desvios padrões acima da média), sua predição correspondente  $\hat{Y}$  será de apenas  $2 \cdot r$  desvios padrões acima da média.
  - O fenômeno foi observado por Francis Galton em estudos de hereditariedade (pais muito altos tendem a ter filhos ligeiramente mais baixos que os pais, aproximando-se da média populacional).

# Erro de Estimativa e Função de Perda

- Para qualquer reta de predição ajustada, existirá um **Erro de Estimativa** (ou Resíduo) para cada ponto:

$$e_i = y_i - \hat{y}_i$$

- Como mensurar a qualidade de ajuste global do modelo?
- Definimos a **Função de Perda** (Loss Function) como a **Raiz do Erro Quadrático Médio** (*RMSE*):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

- Onde  $N$  representa o **Tamanho da Amostra**.
- Nosso objetivo estatístico é encontrar a reta que minimiza o valor de *RMSE*.

# O Método dos Mínimos Quadrados (Least Squares)

- O **Método dos Mínimos Quadrados Ordinários (OLS)** consiste em achar os parâmetros da reta que minimizam a soma dos erros quadrados de predição.
- Em unidades padrão, buscamos o slope  $\beta_{su}$  da reta  $\hat{y}_{su} = \beta_{su} \cdot x_{su}$  que minimize:

$$L(\beta_{su}) = \frac{1}{N} \sum_{i=1}^N (y_{i,su} - \beta_{su} \cdot x_{i,su})^2$$

- Derivando em relação a  $\beta_{su}$  e igualando a zero, prova-se analiticamente que:

$$\beta_{su} = \frac{1}{N} \sum_{i=1}^N x_{i,su} \cdot y_{i,su} = r$$

- **Conclusão:** A reta de regressão em unidades padrão é a melhor reta no sentido dos mínimos quadrados.

# Exemplo Pareado: Otimização Computacional

## Minimizando o RMSE numericamente com SciPy

```
import numpy as np
from scipy.optimize import minimize
from scipy import stats

# Dados originais de exemplo
x = np.array([84.2, 88.1, 91.3, 85.0, 93.4])
y = np.array([89.1, 93.2, 94.5, 90.0, 97.2])

# Z-normalizacao (Unidades Padrao)
x_su = (x - np.mean(x)) / np.std(x, ddof=1)
y_su = (y - np.mean(y)) / np.std(y, ddof=1)

# Funcao de perda: RMSE
def calcular_rmse(beta, x_data, y_data):
    pred = beta[0] * x_data
    return np.sqrt(np.mean((y_data - pred) ** 2))

# Minimizacao numerica da perda
chute = [0.0]
res = minimize(calcular_rmse, chute, method='BFGS')
beta_otimizado = res.x[0]
r_analitico, _ = stats.pearsonr(x, y)

print(f"Beta Otimizado (RMSE): {beta_otimizado:.6f}")
print(f"Pearson r (Analitico): {r_analitico:.6f}")
```

# A Reta nas Unidades Originais

- Desfazendo a Z-normalização, chegamos à equação clássica da reta:

$$\hat{y} = \beta X + \alpha$$

- Fórmula do Coeficiente Angular (Slope  $\beta$ ):**

$$\beta = r \cdot \frac{s_y}{s_x}$$

- Fórmula do Coeficiente Linear (Intercepto  $\alpha$ ):**

$$\alpha = \bar{Y} - \beta \bar{X}$$

- Interpretação Prática:**

- Slope ( $\beta$ ):** Para cada acréscimo de uma unidade física em  $X$ , a predição  $\hat{Y}$  aumenta em  $\beta$  unidades físicas de  $Y$ .
- Intercepto ( $\alpha$ ):** Representa a predição para  $Y$  caso a variável preditora  $X$  assumo o valor zero (deve-se tomar cuidado com a extrapolação fora do domínio amostral).

# Qualidade do Ajuste: Coeficiente de Determinação

- O **Coeficiente de Determinação** ( $R^2$ ) indica a proporção da variabilidade da variável resposta  $Y$  que é explicada pelo modelo linear:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{Y})^2}$$



- **Propriedades de  $R^2$ :**
  - Na regressão linear simples, vale exatamente o quadrado do coeficiente de Pearson ( $R^2 = r^2$ ).
  - Varia no intervalo  $[0, 1]$  para regressões de mínimos quadrados comuns.
  - Exemplo:  $R^2 = 0.65 \implies 65\%$  da variação dos dados de  $Y$  é explicada linearmente em relação a  $X$ .

- O **Gráfico de Resíduos** (Residual Plot) é a principal ferramenta de diagnóstico visual. Consiste em plotar os resíduos  $e_i = y_i - \hat{y}_i$  contra o preditor  $x_i$ .
- **Suposição de Homocedasticidade:** A variabilidade dos resíduos deve ser constante ao longo de todo o eixo X.
- **Padrões Indesejados a Detectar:**
  - ① **Não-Linearidade:** Resíduos formam curvas (ex: padrão em U). Sugere necessidade de transformações ou modelos não-lineares.
  - ② **Heterocedasticidade:** Resíduos apresentam-se em forma de funil (dispersão aumenta com X). Afeta a validade das inferências estatísticas clássicas.

# Diagnósticos Visuais: Homocedasticidade

## Caso 1: Homocedástico (Ideal)


- Os resíduos apresentam-se dispersos de forma aleatória em torno da linha zero.
- A variabilidade (dispersão vertical) é constante ao longo de todo o eixo  $X$ .
- Esta é a situação ideal que valida as inferências e testes de hipóteses clássicos.



# Diagnósticos Visuais: Não-Linearidade

## Caso 2: Não-Linear


- Os resíduos formam uma curvatura clara (formato em U ou padrão parabólico).
- Revela que a relação real entre  $X$  e  $Y$  não é linear.
- **Solução:** Requer transformações nas variáveis (ex: usar  $\log(X)$ ) ou inclusão de termos polinomiais.



# Diagnósticos Visuais: Heterocedasticidade

## Caso 3: Heterocedástico

- A dispersão dos resíduos aumenta ou diminui sistematicamente à medida que  $X$  cresce.
- Produz um padrão visual de "funil".
- **Consequência:** Invalida as fórmulas tradicionais de erro padrão do slope.



# Diagnósticos Numéricos de Regressão

- **Média dos Resíduos:** Na regressão de mínimos quadrados, a média amostral dos resíduos é matematicamente igual a zero:

$$\bar{e} = \frac{1}{N} \sum_{i=1}^N e_i = 0$$

- **Desvio Padrão dos Resíduos ( $SD_{res}$ ):** Mede o espalhamento vertical em torno da reta ajustada:

$$SD_{res} = \sqrt{\frac{\sum e_i^2}{N-2}} \approx \sqrt{1-r^2} \cdot s_y$$

- Onde a aproximação teórica é dada pela multiplicação de  $\sqrt{1-r^2}$  pelo **Desvio Padrão Amostral** da variável resposta  $s_y$ .

# Inferência do Slope por Reamostragem (Bootstrap)

- Em conjuntos de dados amostrais, os coeficientes  $\beta$  e  $\alpha$  possuem incerteza estatística (erro padrão).
- Como construir um **Intervalo de Confiança (IC)** para o slope  $\beta$  sem fazer suposições estritas de normalidade populacional?
- **Bootstrap de Pares:**
  - 1 Sorteamos com reposição linhas completas da tabela amostral de tamanho  $N$ .
  - 2 Ajustamos uma reta para esta nova amostra Bootstrap e guardamos o slope  $\beta_{boot}$ .
  - 3 Repetimos o processo 2000 vezes para gerar a distribuição empírica do slope.
  - 4 Extraímos as posições 2.5% e 97.5% para formar o Intervalo de Confiança (IC) de 95%.

# Exemplo Real: Comprimento e Cabeça de Gambás

## Comparação: Bootstrap vs. Statsmodels

```
import statsmodels.api as sm
import numpy as np

# X = comprimento do corpo (cm), Y = comprimento da cabeça (mm)
# Amostra simulada de 140 gambas
X_sm = sm.add_constant(comprimento_corpo)
modelo = sm.OLS(comprimento_cabeca, X_sm).fit()

print(modelo.summary().tables[1])
# Tabela classica reporta:
# const: coef = 42.6419 | IC 95% = [36.490, 48.794]
# x1:      coef = 0.5743 | IC 95% = [0.504, 0.644]

# Comparacao com Bootstrap de Pares:
# Slope estimado: 0.5743
# IC 95% Bootstrap: [0.5042, 0.6484]
```

Os métodos concordam fortemente, validando o uso de ferramentas de simulação.