

Função de Verossimilhança

Máxima Verossimilhança para Modelos Discretos e Contínuos

Tecnologia em Análise e Desenvolvimento de Sistemas
Ciência de Dados / Estatística Computacional

Instituto Federal do Ceará – Campus Tauá
Tecnologia em Análise e Desenvolvimento de Sistemas

22 de agosto de 2026

Sumário da Aula

- 1 Função de Verossimilhança de Bernoulli
- 2 Verossimilhança Gaussiana e Atividade

O que é Verossimilhança?

- Até o momento, avaliamos o ajuste de modelos por meio de critérios puramente geométricos (como a minimização do Erro Quadrático Médio).
- A **Função de Verossimilhança** (L) nos permite estimar parâmetros de modelos sob uma perspectiva probabilística.
- **Cenário Dedutivo (Probabilidade):**
 - Os parâmetros populacionais θ são conhecidos (ex: moeda justa, $\theta = 0.5$).
 - Queremos calcular a chance de observar um determinado conjunto de dados.
- **Cenário Indutivo (Inferência/Verossimilhança):**
 - Os dados amostrais já foram coletados e estão fixos.
 - Queremos avaliar a plausibilidade de diferentes valores do parâmetro θ .

O Modelo Discreto: Ensaios de Bernoulli

- Considere uma sequência de lançamentos de moedas independentes.
- Cada lançamento $X_i \in \{0, 1\}$ segue uma distribuição de Bernoulli com $P(X_i = 1) = \theta$.
- A Função de Massa de Probabilidade (PMF) de Bernoulli é escrita como:

$$P(X_i = x_i) = \theta^{x_i} (1 - \theta)^{1-x_i}$$

- Assumindo observações independentes e identicamente distribuídas, a **Função de Verossimilhança** de uma amostra de tamanho N é o produto das PMFs individuais:

$$L(\theta) = \prod_{i=1}^N P(X_i = x_i) = \prod_{i=1}^N \theta^{x_i} (1 - \theta)^{1-x_i}$$

$$L(\theta) = \theta^{\sum_{i=1}^N x_i} (1 - \theta)^{N - \sum_{i=1}^N x_i}$$


Visualizando a Verossimilhança de Bernoulli

Experimento Prático:

- Jogamos uma moeda $N = 13$ vezes e observamos 4 caras (1) e 9 coroas (0).
- A função de verossimilhança é:

$$L(\theta) = \theta^4(1 - \theta)^9$$

- **Ponto de Máximo:** Graficamente, a plausibilidade é maximizada em $\theta \approx 0.3077$.
- **Desafio Numérico:** Os valores de $L(\theta)$ são muito pequenos (na ordem de 10^{-4}).



A Escala de Log-Verossimilhança

- Para computadores, multiplicar dezenas ou centenas de probabilidades menores que 1 gera **subfluxo numérico** (underflow), onde o produto é arredondado para zero.
- Aplicando a função de logaritmo natural ($\ln$) na verossimilhança, convertemos produtos em somatórios:

$$\ln L(\theta) = \ln \left(\prod_{i=1}^N P(X_i = x_i) \right) = \sum_{i=1}^N \ln P(X_i = x_i)$$

- Como a função $\ln(y)$ é estritamente crescente, o valor de θ que maximiza a log-verossimilhança é o mesmo que maximiza a verossimilhança original.
- Para o caso de Bernoulli:

$$\ln L(\theta) = \left(\sum_{i=1}^N x_i \right) \ln \theta + \left(N - \sum_{i=1}^N x_i \right) \ln(1 - \theta)$$


Visualizando a Log-Verossimilhança

Escala de Log-Verossimilhança:

- O valor máximo da curva ocorre no mesmo ponto:

$$\theta \approx 0.3077$$

- A escala no eixo vertical agora varia em valores negativos mais estáveis (não decai para zero).
- Facilita a modelagem computacional e a obtenção das derivadas.



Exemplo Pareado: Solução Analítica

- Queremos encontrar o valor de θ que maximiza a log-verossimilhança:

$$\ln L(\theta) = \left(\sum x_i\right) \ln \theta + (N - \sum x_i) \ln(1 - \theta)$$

- Derivamos com relação ao parâmetro θ e igualamos a zero para achar o ponto crítico:

$$\frac{d \ln L(\theta)}{d\theta} = \frac{\sum x_i}{\theta} - \frac{N - \sum x_i}{1 - \theta} = 0$$

$$\frac{\sum x_i}{\theta} = \frac{N - \sum x_i}{1 - \theta} \implies (1 - \theta) \sum x_i = \theta(N - \sum x_i)$$

$$\sum x_i - \theta \sum x_i = \theta N - \theta \sum x_i \implies \hat{\theta}_{MLE} = \frac{\sum x_i}{N}$$

- Conclusão:** A Estimativa de Máxima Verossimilhança ($\hat{\theta}_{MLE}$) para a proporção é a própria proporção amostral dos dados.

Exemplo Pareado: Implementação em Python

Calculando a Log-Verossimilhança de Bernoulli

```
import numpy as np

# Dados do experimento (4 caras, 9 coroas)
dados = np.array([1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0])
N = len(dados)
sucessos = np.sum(dados)
fracassos = N - sucessos

# Proporcao empirica (MLE)
theta_otimo = sucessos / N
print(f"MLE de theta: {theta_otimo:.4f}") # Saida: 0.3077

# Funcao de log-verossimilhanca
def log_verossimilhanca(theta, k, n):
    return k * np.log(theta) + (n - k) * np.log(1 - theta)

# Testando valores candidatos de theta
for theta in [0.1, 0.3077, 0.5, 0.8]:
    ll = log_verossimilhanca(theta, sucessos, N)
    print(f"Theta: {theta:.4f} | Log-Verossimilhanca: {ll:.4f}")
```

Modelagem de Dados Contínuos: A Normal

- Para dados contínuos, a verossimilhança é formulada utilizando a **Função de Densidade de Probabilidade (PDF)**.
- Assumimos que a nossa amostra segue uma distribuição Normal $N(\mu, \sigma^2)$:

$$f(x_i|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

- Onde μ é a **Média Populacional** e σ^2 é a **Variância Populacional**.
- A verossimilhança conjunta para N observações independentes é dada pelo produto:

$$L(\mu, \sigma^2) = \prod_{i=1}^N f(x_i|\mu, \sigma^2) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-N/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^N (x_i - \mu)^2\right)$$

A Log-Verossimilhança Gaussiana

- Aplicando a transformação logarítmica natural ($\ln$) à verossimilhança Normal:

$$\ln L(\mu, \sigma^2) = \ln \left[(2\pi\sigma^2)^{-N/2} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^N (x_i - \mu)^2 \right) \right]$$

$$\ln L(\mu, \sigma^2) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (x_i - \mu)^2$$

- **A Conexão com Mínimos Quadrados:**

- Para maximizar a verossimilhança com relação à média μ , a primeira parcela é constante.
- Portanto, devemos ****maximizar**** a segunda parcela, o que equivale a ****minimizar**** o somatório $\sum_{i=1}^N (x_i - \mu)^2$.
- Esse somatório é exatamente a soma dos erros quadráticos!

Estimadores de Máxima Verossimilhança

- Derivando a log-verossimilhança com relação a μ e igualando a zero:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^N (x_i - \mu) = 0 \implies \hat{\mu}_{MLE} = \frac{1}{N} \sum_{i=1}^N x_i = \bar{X}$$

- Derivando com relação a σ^2 e igualando a zero:

$$\frac{\partial \ln L}{\partial (\sigma^2)} = -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^N (x_i - \mu)^2 = 0 \implies \hat{\sigma}_{MLE}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{X})^2$$


- Nota Importante:** O estimador de máxima verossimilhança da variância divide por N e não por $N - 1$. Isso o torna ligeiramente viesado para pequenas amostras.

Visualizando a Log-Verossimilhança Normal

Análise da Média Amostral:

- Utilizando a amostra de 170 medições de sala.
- Mantemos o desvio padrão constante no seu valor ótimo $\hat{\sigma} \approx 16.6020$.
- Avaliamos diferentes médias candidatas μ .
- A log-verossimilhança Gaussiana atinge o seu valor máximo exatamente em:

$$\hat{\mu}_{MLE} = 46.5412$$



Implementando a Log-Verossimilhança Normal em Python

```
import numpy as np
import scipy.stats as ss

# Amostra de medicoes
dados = np.array([41, 27, 33, 58, 24, 65, 48, 72, 36, 29, 54, 67, 21])

# Estimativas pontuais amostrais
media_amostral = np.mean(dados)
std_amostral = np.std(dados) # MLE divide por N

print(f"Media amostral: {media_amostral:.4f}")

# Funcao de log-verossimilhanca Normal usando scipy
def log_verossimilhanca_normal(dados, mu, sigma):
    pdf_valores = ss.norm.pdf(dados, loc=mu, scale=sigma)
    return np.sum(np.log(pdf_valores))

# Avaliando medias candidatas
for mu_cand in [30.0, media_amostral, 60.0]:
    ll = log_verossimilhanca_normal(dados, mu_cand, std_amostral)
    print(f"Mu candidato: {mu_cand:.4f} | Log-Verossimilhanca: {ll:.4f}")
```

- Abra um Jupyter Notebook no ambiente do curso.
- **Tarefa 1 (Simulação de Moeda):**
 - Simule 100 lançamentos de moeda com probabilidade $\theta = 0.65$.
 - Implemente a função de log-verossimilhança de Bernoulli.
 - Plote a curva de log-verossimilhança para um grid de valores candidatos e identifique o ponto de máximo.
- **Tarefa 2 (Dados Gaussianos):**
 - Simule 50 observações normais com média $\mu = 30$ e desvio padrão $\sigma = 5$.
 - Crie uma função para calcular a log-verossimilhança normal.
 - Mantenha $\sigma = 5.0$ fixo e avalie a plausibilidade para médias de 20 a 40.
 - Verifique se o máximo numérico coincide com a média amostral observada.