

Avaliação Prática Unificada

Construção de Pipeline ETL com Fundamentação em Ciência de Dados

Disciplina: Ciência de Dados

Data de Entrega: 23/06/2026

Formato: Grupos ou Individual

1 Objetivo da Avaliação

Esta avaliação visa integrar os conhecimentos técnicos de engenharia de dados (ETL, POO, SRP) com os fundamentos teóricos de Ciência de Dados (Inferência Causal, Amostragem e Estatística). O objetivo é construir um pipeline que não apenas processe dados, mas que seja projetado com consciência sobre a natureza e as limitações estatísticas da informação.

2 Escolha do Tema e Fontes de Dados (Kaggle)

Cada equipe deverá escolher **um** dos temas abaixo. O processo de **Extração** (*Extract*) deve obrigatoriamente consumir as fontes indicadas do Kaggle.

- **Opção A: Logística e Segurança Viária**
<https://www.kaggle.com/datasets/rafaelborgesgraunke/traffic-accidents-brazil-pt-br>
- **Opção B: Finanças e E-Commerce**
<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- **Opção C: Meio Ambiente (Queimadas)**
<https://www.kaggle.com/datasets/gustavomodelli/forest-fires-in-brazil>
- **Opção D: Saúde Pública (COVID-19)**
<https://www.kaggle.com/datasets/gpreda/covid19-vaccination-track-everywhere-in-the-world>
- **Opção E: Educação e Desempenho**
<https://www.kaggle.com/datasets/cansa23/higher-education-students-performance-evaluation>

3 Detalhamento das Atividades (Aplicação de Conceitos)

3.1 Camada de Extração (Amostragem e Viés)

- **Desenvolvimento:** Implementar a classe de extração resiliente (try/except) conforme solicitado anteriormente.

- **Aplicação Teórica (README):** No documento do projeto, identifique a **População-alvo** que os dados deveriam representar e qual é a **Estrutura de Acesso** (Access Frame) real oferecida pelo Kaggle. Discuta se há risco de **Viés de Seleção** na forma como esses dados foram coletados.

3.2 Camada de Transformação (Tipagem e Variáveis)

- **Desenvolvimento:** Padronização, limpeza e normalização de datas (ISO).
- **Dicionário de Dados:** No README, além de listar os tipos técnicos (int, float), você deve classificar cada variável final como **Discreta** ou **Contínua**.
- **Tratamento de Nulos (Viés vs Variância):** Justifique sua estratégia de tratamento de valores nulos (exclusão ou imputação). Explique o impacto dessa escolha no **Viés** e na **Variância** do seu dataset final.

3.3 Análise de Domínio (Inferência Causal e Ceteris Paribus)

- **Aplicação Teórica (README):** Escolha uma relação entre duas variáveis do seu tema (ex: Chuva e Acidentes).
 1. Explique por que uma correlação encontrada não implica necessariamente causalidade.
 2. Cite duas possíveis **Variáveis de Confusão** que poderiam afetar essa análise.
 3. Descreva como seria um cenário **Ceteris Paribus** ideal para testar essa relação.

3.4 Camada de Visualização (Integridade Visual)

- **Desenvolvimento:** Crie um script `src/visualize.py` que utilize os dados limpos para gerar **um** dos gráficos abaixo, seguindo rigorosamente os princípios de visualização (ex: eixos iniciando em zero):
 - Evolução temporal (Linhas).
 - Distribuição de categorias (Barras).
 - Relação entre duas variáveis numéricas (Dispersão).

4 Estrutura do Projeto

```

meu-projeto-etl/
├── src/
│   ├── extract/extractor.py
│   ├── transform/cleaner.py
│   ├── visualize.py
│   ├── utils/logger.py
│   ├── main.py
│   └── README.md

```

Novo: Visualização de dados

Contendo fundamentação teórica

5 Critérios de Avaliação

Critério	Peso
Qualidade Técnica (POO, SRP, Resiliência)	40%
Fundamentação de Ciência de Dados (README e Análise)	40%
Visualização e Integridade de Dados	20%