

Avaliação Prática Unificada (Parte 1)

Construção de Pipeline de Dados com Fundamentação em Ciência de Dados

Disciplina: Ciência de Dados
Data de Entrega: 28/06/2026
Formato: Grupos ou Individual

1 Objetivo da Avaliação

Esta avaliação visa integrar os conhecimentos práticos de manipulação de dados com os fundamentos teóricos de Ciência de Dados (Inferência Causal, Amostragem, Análise Exploratória e Estatística). O objetivo é construir um pipeline reproduzível que não apenas processe os dados, mas que seja projetado com plena consciência sobre a natureza, as limitações estatísticas e a integridade analítica da informação.

2 Escolha do Tema e Fontes de Dados (Kaggle)

Cada equipe deverá escolher **um** dos temas abaixo. O processo de extração deve obrigatoriamente consumir as fontes indicadas do Kaggle.

- **Opção A: Logística e Segurança Viária**
<https://www.kaggle.com/datasets/rafaelborgesgraunke/traffic-accidents-brazil-pt-br>
- **Fonte Secundária Auxiliar:**
<https://www.kaggle.com/datasets/liamarguedas/brazil-total-highway-crashes-2010-2023>
- **Opção B: Finanças e E-Commerce**
<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- **Opção C: Meio Ambiente (Queimadas)**
<https://www.kaggle.com/datasets/gustavomodelli/forest-fires-in-brazil>
- **Opção D: Saúde Pública (COVID-19)**
<https://www.kaggle.com/datasets/gpreda/covid-world-vaccination-progress>
- **Opção E: Educação e Desempenho**
<https://www.kaggle.com/datasets/csafrit2/higher-education-students-performance-evaluation>
- **Opção F: Energia, Clima e Recursos Renováveis**
<https://www.kaggle.com/datasets/pythonafroz/renewable-power-generation-and-weather-conditions>

3 Detalhamento das Atividades (Aplicação de Conceitos)

3.1 Camada de Ingestão (Amostragem e Viés)

Vocês devem construir o script de captura e leitura inicial dos dados brutos (`extractor.py`).

- **Desenvolvimento:** Implementar a leitura automatizada dos arquivos `.csv` originais e isolar falhas de caminhos de arquivos por meio de tratamento de erros. O script deve registrar um log simples informando as dimensões iniciais da matriz de dados (volumetria bruta).
- **Aplicação Teórica (README):** Na documentação do projeto, identifique explicitamente qual seria a **População-alvo** ideal que os dados do seu tema deveriam representar e qual é a **Estrutura de Acesso** (*Access Frame*) real oferecida pelo dataset disponível no Kaggle. Discuta criticamente se há riscos de **Viés de Seleção** na forma como esses dados foram originalmente coletados.

3.2 Análise Exploratória e Tratamento Estatístico (EDA)

Vocês devem estruturar as regras de transformação e higienização das variáveis (`cleaner.py`).

- **Desenvolvimento (Sanitização e IQR):** Identificar e tratar falhas de codificação de texto (*encoding*) e padronizar strings categóricas. Implementar algoritmicamente o cálculo estatístico do **Intervalo Interquartil (IQR)** para as colunas numéricas contínuas mais relevantes, isolando os *outliers* de forma automatizada para evitar distorções estatísticas.
- **Dicionário de Dados:** No `README.md`, monte uma tabela com o esquema final do dataset. Classifique obrigatoriamente cada variável tratada sob a ótica da modelagem estatística como **Discreta**, **Contínua** ou **Categórica**.
- **Tratamento de Nulos (Viés vs Variância):** Justifique explicitamente no relatório a estratégia adotada (exclusão de registros ou imputação por medidas de tendência central). Explique o impacto teórico dessa decisão no **Viés** (erros sistemáticos) e na **Variância** (sensibilidade a novos dados) do seu conjunto final.
- **Consolidação Lógica (Merge):** Realizar o cruzamento das tabelas por chaves comuns (ex: códigos geográficos, IDs). O código deve mitigar disparidades nas chaves para evitar a perda silenciosa de amostras significativas durante o *join*.

3.3 Análise de Domínio (Inferência Causal e Ceteris Paribus)

Esta seção será avaliada exclusivamente pela profundidade conceitual e científica demonstrada na documentação.

- **Aplicação Teórica (README):** Escolha uma relação hipotética ou lógica entre duas variáveis do tema do seu dataset (ex: *Intensidade de Chuva* e *Volume de Acidentes*; *Renda Familiar* e *Acesso à Educação superior*; *Radiação Solar* e *Eficiência do Painel*). Responda com rigor científico:

- Explique detalhadamente por que uma forte correlação matemática encontrada entre essas variáveis não é evidência suficiente para comprovar um nexo de causalidade.
- Identifique e disserte sobre pelo menos duas possíveis **Variáveis de Confusão** (*confounders*) omitidas que poderiam enviesar os resultados caso fossem ignoradas.
- Descreva conceitualmente como seria o desenho de um cenário ideal sob a ótica do princípio do **Ceteris Paribus** para isolar e validar adequadamente o efeito causal dessa relação.

3.4 Visualização Científica (Integridade Visual)

Vocês devem criar uma camada visual dedicada para traduzir graficamente os insights coletados.

- **Desenvolvimento:** Construa o script `visualize.py` que utilize a base de dados tratada pelo pipeline para gerar de forma automatizada **um** dos seguintes gráficos:
 - Evolução temporal da métrica principal (Gráfico de Linhas).
 - Distribuição proporcional de atributos qualitativos (Gráfico de Barras).
 - Relação e dispersão entre duas variáveis numéricas (Gráfico de Dispersão).
- **Integridade Visual:** O gráfico exportado deve respeitar estritamente os princípios de ética e honestidade visual em Ciência de Dados, contendo eixos devidamente identificados, unidades de medida explícitas, escalas proporcionais coerentes (eixos numéricos iniciando em zero onde aplicável) e ausência total de distorções visuais.

4 Estrutura do Projeto e Entregáveis

O repositório do projeto no **Git** deve seguir o formato mínimo e organizado especificado abaixo para garantir a reprodutibilidade analítica:

```

meu-projeto-data-science/
├── src/
│   ├── extract/
│   │   └── extractor.py
│   ├── transform/
│   │   └── cleaner.py
│   ├── visualize.py
│   └── main.py
├── requirements.txt
└── README.md

```

Script de ingestão e leitura de arquivos

Script com tratamento estatístico (Nulos e IQR)

Script focado em gráficos de integridade visual

Orquestrador central de execução do pipeline

Dependências de bibliotecas de análise

Relatório científico e documentação teórica

O pipeline de execução deve gerar de forma automatizada o arquivo final limpo na raiz do projeto sob o nome `dados_limpos_final.csv` (ou `.json`), representando a base consolidada para futuras inferências.

5 Critérios de Avaliação

Critério de Avaliação Científica	Peso
Manipulação Estatística de Dados (EDA): Qualidade algorítmica no tratamento de nulos, inconsistências de tipos, pareamento de dados e isolamento matemático de outliers via IQR.	40%
Fundamentação de Ciência de Dados: Rigor conceitual na análise de viés de amostragem, modelagem de variáveis e justificativa das hipóteses de inferência causal e confusão no README.	40%
Visualização e Integridade: Geração via script automatizado do gráfico escolhido sob os critérios de honestidade estatística e ética visual.	20%