

Avaliação Prática Unificada (Parte 2)

Inferência Estatística, Testes A/B e Causalidade

Disciplina: Ciência de Dados

Data de Entrega: 01/09/2026

Formato: Grupos (os mesmos da Parte 1) ou Individual

1 Contextualização do Projeto

Este projeto prático integrado é estruturado em duas etapas consecutivas:

- **Parte 1 (Já Implementada):** Focada na infraestrutura de engenharia e limpeza de dados (ETL). Cada equipe desenvolveu os mecanismos de ingestão programática (`extractor.py`), a higienização e imputação de valores nulos, o isolamento estatístico de valores extremos via Intervalo Interquartil (IQR), a unificação de tabelas relacionais (`cleaner.py`) e a exportação do arquivo final consolidado `dados_limpos_final.csv`.
- **Parte 2 (Etapa Atual):** Focada na modelagem estatística, testagem empírica e raciocínio causal. A partir da base de dados limpa resultante da Parte 1, serão adicionados os novos conceitos inferenciais estudados em sala de aula (Bootstrap, Intervalos de Confiança, Testes de Permutação e Causalidade).

2 Objetivo da Avaliação (Parte 2)

Esta etapa visa aplicar os métodos de inferência computacional e estatística das Aulas 8 a 12 (Teorema Central do Limite, Bootstrap, Teste A/B, Testes de Permutação e Causalidade) para testar hipóteses e guiar tomadas de decisão baseadas em dados sobre o conjunto tratado anteriormente.

3 Dados de Entrada

As equipes devem utilizar obrigatoriamente o dataset unificado e limpo (`dados_limpos_final.csv`) resultante do pipeline de ETL desenvolvido na Parte 1.

4 Detalhamento das Atividades (Estruturação Estatística)

4.1 Estimação de Parâmetros e Bootstrap (Aulas 8, 9, 10)

Nesta atividade, a equipe estimará parâmetros populacionais de interesse a partir das amostras observadas.

- **Desenvolvimento (bootstrap.py):** Escolha uma variável numérica contínua chave do seu dataset (Ex: valor de transação, tempo de atendimento, precipitação climática, nota de avaliação).

1. Calcule a Média Amostral ($\bar{X}$) e o Desvio Padrão Amostral (s) observados.
2. Implemente algoritmicamente um processo de **reamostragem Bootstrap** com pelo menos 2.000 réplicas com reposição para gerar a distribuição empírica da média.
3. Construa um **Intervalo de Confiança (IC)** de 95% para a média populacional utilizando duas metodologias:
 - **Método Não-Paramétrico (Bootstrap):** Extraíndo os percentis 2.5% e 97.5% da distribuição empírica.
 - **Método Paramétrico Tradicional:** Utilizando a aproximação normal com base no erro padrão analítico:

$$IC_{95\%} = \bar{X} \pm z_{95\%} \cdot \frac{s}{\sqrt{N}}$$

Onde N representa o Tamanho da Amostra e $z_{95\%} \approx 1.96$ é o valor crítico de z .

4. Exporte um gráfico de distribuição mostrando o histograma das médias bootstrap com as linhas verticais indicando os limites dos dois intervalos calculados.
- **Discussão Científica (README):** Na documentação, descreva os limites encontrados e compare as duas metodologias de intervalo de confiança. Justifique se as condições do **Teorema Central do Limite (TCL)** se aplicam à sua variável amostral com base no tamanho da amostra N e no comportamento de assimetria dos dados.

4.2 Teste de Hipóteses e Teste A/B (Aulas 10, 11)

Nesta seção, a equipe modelará e testará estatisticamente uma hipótese nula de igualdade entre dois grupos (Cenários A e B).

- **Definição dos Grupos de Teste:** Cada equipe deve segmentar os dados em dois sub-grupos mutuamente exclusivos com base em seu tema. Exemplos sugeridos:
 - **Logística:** Acidentes graves/fatais (Grupo A) vs. Leves/sem vítimas (Grupo B) quanto à distância de frenagem ou velocidade.
 - **E-Commerce:** Compras pagas via Cartão de Crédito (Grupo A) vs. Boleto Bancário (Grupo B) quanto ao ticket médio.
 - **Meio Ambiente:** Focos de queimada no Período Seco (Grupo A) vs. Período Chuvoso (Grupo B).
 - **Saúde Pública:** Estados com Alta Cobertura Vacinal (Grupo A) vs. Baixa Cobertura (Grupo B) quanto à taxa de internações.
 - **Educação:** Estudantes com acesso a internet/apoio escolar (Grupo A) vs. Sem acesso (Grupo B) quanto às notas finais.

- **Desenvolvimento (ab_testing.py):**

1. Formule e declare explicitamente a Hipótese Nula (H_0) e a Hipótese Alternativa (H_1) utilizando nomenclatura estatística formal.

2. Estabeleça o **Limite de Significância** (α) padrão de 5% ($\alpha = 0.05$).
 3. Calcule a estatística de teste observada (ex: diferença entre as médias amostrais dos dois grupos, $\bar{X}_A - \bar{X}_B$).
 4. Implemente um **Teste de Permutação** (embaralhamento de rótulos) com no mínimo 2.000 iterações para simular a distribuição da estatística sob a validade de H_0 .
 5. Calcule o **Valor-p** (p-value) empírico bicaudal a partir da proporção de permutações que geraram estatísticas tão ou mais extremas que a observada.
 6. Salve o gráfico contendo o histograma da distribuição sob a hipótese nula com uma linha de destaque indicando a posição da diferença observada na amostra real.
- **Análise Crítica (README):** Conclua formalmente se a hipótese nula (H_0) deve ser rejeitada ou não ao nível de significância de 5%. Explique o significado prático desse resultado no domínio do negócio.

4.3 Modelagem Preditiva Supervisionada (Regressão e Classificação)

Nesta etapa, a equipe utilizará modelos supervisionados para predição.

- **Desenvolvimento (Regressão Múltipla – regression.py):**
 1. Escolha uma variável resposta quantitativa Y e pelo menos duas variáveis preditoras X_1, X_2 .
 2. Ajuste um modelo de **Regressão Linear Múltipla**.
 3. Reporte e interprete os coeficientes estimados ($\beta_0, \beta_1, \beta_2$) sob a ótica do princípio do *Ceteris Paribus* (tudo o mais constante).
 4. Apresente a qualidade do ajuste através do **Coefficiente de Determinação** (R^2) e da **Raiz do Erro Quadrático Médio** (RMSE).
- **Desenvolvimento (Modelos de Classificação – machine_learning.py):**
 1. Defina uma tarefa de classificação binária no seu conjunto de dados (Ex: transação fraudulenta vs. legítima, acidente grave vs. leve, aprovação do aluno).
 2. Implemente um pipeline usando a biblioteca **Scikit-Learn (SKLearn)**, contendo o pré-processamento dos dados (normalização/padronização).
 3. Compare o desempenho de dois algoritmos estudados: **Regressão Logística** e **K-Vizinhos Mais Próximos (KNN)**.
 4. Utilize a técnica de **Validação Cruzada** (*Cross-Validation*) com o método **Grid-SearchCV** para a busca e otimização dos melhores hiperparâmetros dos modelos.
 5. Reporte a Matriz de Confusão, Acurácia, Precisão, Sensibilidade (*Recall*) e a pontuação F1-Score no conjunto de teste.

4.4 Aprendizado Não Supervisionado e Redução de Dimensionalidade

Nesta etapa, a equipe aplicará técnicas para agrupar observações e simplificar a estrutura de dados.

- **Desenvolvimento (unsupervised.py):**
 1. **Redução de Dimensionalidade (PCA):** Aplique a técnica de **Análise de Componentes Principais (PCA)**, previamente fundamentada pela **Decomposição em Valores Singulares (SVD)**, nas variáveis numéricas do seu dataset. Projete as observações no plano dos dois primeiros componentes principais e gere o gráfico de dispersão correspondente.
 2. **Clusterização (K-Means):** Implemente o algoritmo de agrupamento **K-Means** para identificar grupos naturais de dados.
 3. Utilize o **Método do Cotovelo** (*Elbow Method*) para determinar o número ótimo de clusters (k), plotando a inércia contra k .
 4. Salve a projeção dos dados identificando visualmente cada cluster por cores distintas.
- **Discussão Científica (README):** Explique a variância explicada acumulada pelos dois primeiros componentes do PCA. Disserte sobre o significado prático/físico dos clusters gerados pelo K-Means no contexto do seu tema.


4.5 Inferência Causal e Tomada de Decisão (Aula 12)

Esta seção avalia a maturidade teórica da análise para além da correlação estatística e preditiva.

- **Aplicação Teórica (README):** Com base nos modelos preditivos e testes realizados:
 - a) Avalie criticamente se as relações identificadas pelos modelos supervisionados representam conexões causais ou apenas correlações complexas.
 - b) Identifique potenciais variáveis de confusão que violam a hipótese de independência estatística necessária para a validade dos modelos clássicos.
 - c) Proponha uma tomada de decisão operacional fundamentada no comportamento dos clusters ou das previsões obtidas.

5 Estrutura do Projeto e Entregáveis

O repositório do Git deve ser atualizado incluindo a nova camada de inferência estatística e modelagem, conforme a estrutura arquitetural expandida abaixo:



O orquestrador `main.py` deve executar de forma integrada todo o pipeline de dados, gerando e salvando na raiz do projeto as seguintes imagens estatísticas e analíticas:

- `distribuicao_bootstrap.png`: Histograma de bootstrap e os limites do IC.
- `distribuicao_permutacao.png`: Teste de permutação sob a hipótese nula.
- `curva_cotovelo_kmeans.png`: Método do cotovelo para definição do número de clusters.
- `clusters_kmeans.png`: Gráfico com a projeção dos clusters formados.
- `pca_projecao.png`: Gráfico com a projeção dos componentes principais.

6 Critérios de Avaliação

Critério de Avaliação Prática 2	Peso
Inferência e Estimação Estatística: Lógica da reamostragem bootstrap, intervalos de confiança e teste de permutação para p-valor.	25%
Modelagem Preditiva Supervisionada: Ajuste e interpretação da regressão múltipla, implementação do pipeline de classificação (KNN/Regressão Logística) com GridSearchCV e Validação Cruzada via SKLearn.	30%
Aprendizado Não Supervisionado: Redução de dimensionalidade com PCA (SVD) e agrupamento K-Means selecionando k pelo método do cotovelo.	20%
Raciocínio Causal e Discussão Teórica: Discussão teórica de confundidores, Ceteris Paribus e interpretação dos modelos e clusters no README.	15%
Reprodutibilidade e Organização: Orquestração de rotinas no <code>main.py</code> , gráficos de distribuição limpos e estruturação limpa do código Python.	10%