

 INSTITUTO FEDERAL Ceará Campus Tauá	INSTITUTO FEDERAL DO CEARÁ Campus Tauá	
	Disciplina: Ciência de Dados	Data:
	Professor(a): Prof. Reginaldo Fernandes	
	Discente:	Matrícula:
	Curso: Análise e Desenvolvimento de Sistemas	Semestre: 5º
1ª Avaliação Teórica		
Orientações gerais: 1- Sua avaliação consta de 13 questões, somando 12 pontos. É proibido utilizar consultas. 2- A posse de celular durante a avaliação será entendida como cola, independentemente do uso.		

Questão:	1	2	3	4	5	6	7	8	9	10	11	12	13	Total
Valor:	1	1	1	1	1	1	1	1	1	1	1	1	0	12
Pontuação:														

1. (1 ponto) Um estudo observacional identificou que pessoas que consomem chocolate regularmente apresentam menor incidência de doenças cardiovasculares.

Explique por que essa observação não é suficiente para concluir que o consumo de chocolate causa melhora da saúde cardiovascular. Cite duas possíveis variáveis de confusão e explique como elas podem afetar a interpretação dos resultados.

2. (1 ponto) Explique o papel da randomização em um experimento controlado.

- Na sua resposta, descreva:
- (a) O que é um grupo de tratamento;
 - (b) O que é um grupo de controle;
 - (c) Como a randomização reduz o efeito das variáveis de confusão.

3. (1 ponto) O conceito de *ceteris paribus* é frequentemente utilizado em estudos observacionais.

- Explique:
- (a) O significado da expressão;
 - (b) Por que ela é importante na inferência causal;
 - (c) Por que é mais difícil obter um cenário *ceteris paribus* em estudos observacionais do que em experimentos controlados.

4. (1 ponto) Considere um estudo que deseja analisar o perfil dos estudantes universitários brasileiros.

Foram coletadas respostas apenas de usuários ativos de uma rede social específica.

- Explique a diferença entre:
- (a) População-alvo;
 - (b) Estrutura de acesso (*access frame*);
 - (c) Amostra coletada.

Discuta também como um viés de seleção pode comprometer os resultados do estudo mesmo quando milhões de respostas são obtidas.

5. (1 ponto) Defina os conceitos de:

- (a) Parâmetro populacional;
- (b) Estimador;
- (c) Estimativa.

Explique por que a média amostral é considerada uma variável aleatória enquanto a média populacional é um valor fixo.

6. (1 ponto) Considere uma moeda justa.

Explique o que afirma a Lei dos Grandes Números e por que ela é importante para a construção de modelos estatísticos.

Utilize o lançamento de moedas como exemplo.

7. (1 ponto) Considere dois modelos de previsão:

- Modelo A: produz resultados muito próximos entre si, porém sistematicamente acima do valor real.
- Modelo B: produz resultados centrados no valor real, porém bastante dispersos.

Identifique qual modelo apresenta:

- (a) Alto viés e baixa variância;
- (b) Baixo viés e alta variância.

Explique os riscos de cada situação para aplicações de Ciência de Dados.

8. (1 ponto) Classifique cada variável como **discreta** ou **contínua**.

1. Número de alunos matriculados em uma disciplina.
2. Tempo de resposta de um servidor.
3. Quantidade de acessos a um sistema.
4. Altura dos estudantes.
5. Número de erros encontrados em um software.

Justifique suas respostas.

9. (1 ponto) Dale e Krueger realizaram um estudo para investigar uma questão bastante discutida: estudantes que frequentam universidades mais prestigiadas realmente obtêm salários maiores por causa da instituição ou porque já eram alunos mais qualificados antes de ingressarem nela?

Para responder a essa pergunta, os pesquisadores analisaram estudantes que haviam se candidatado às mesmas universidades. Em vez de comparar apenas alunos de instituições diferentes, eles compararam estudantes com perfis acadêmicos semelhantes, utilizando informações sobre quais universidades os haviam aceitado ou rejeitado. Dessa forma, buscaram criar grupos mais comparáveis e reduzir o efeito de fatores externos.

Com base nesse estudo, explique:

- (a) Por que comparar simplesmente alunos de universidades diferentes pode produzir conclusões equivocadas;
- (b) Como o pareamento por aceitações e rejeições ajuda a aproximar um cenário de “*todo o resto igual*”;
- (c) Qual problema metodológico essa estratégia procura reduzir.

10. (1 ponto) Uma pesquisa deseja estimar a média das notas dos estudantes de uma instituição. Explique:
- (a) Por que o tamanho da amostra influencia a qualidade da estimativa;
 - (b) Por que uma amostra grande nem sempre é representativa;
 - (c) O que caracteriza uma amostra representativa.


11. (1 ponto) Um cientista de dados precisa apresentar os seguintes resultados para a diretoria:
1. Evolução mensal da taxa de evasão dos alunos ao longo de três anos.
 2. Distribuição dos estudantes por curso.
 3. Relação entre horas de estudo e nota final dos alunos.

Para cada situação, indique qual visualização é mais adequada entre:

- Gráfico de linhas;
- Gráfico de barras;
- Gráfico de dispersão;
- Gráfico de pizza.

Justifique sua escolha explicando qual característica dos dados torna a visualização adequada.

12. (1 ponto) Uma empresa apresentou o gráfico abaixo para demonstrar o crescimento das vendas entre 2023 e 2024.



O analista informou que o eixo vertical do gráfico original foi configurado para iniciar em 950 e não em 0.

- Responda:
- (a) Por que iniciar o eixo vertical em 950 pode induzir interpretações equivocadas sobre os resultados?
 - (b) O crescimento apresentado parece maior ou menor do que realmente é? Justifique.
 - (c) Quais princípios de visualização de dados estão sendo violados nessa situação?
 - (d) Como o gráfico poderia ser redesenhado para representar os dados de forma mais transparente para os gestores?
 - (e) Calcule a variação percentual das vendas entre 2023 e 2024.

13. Escolha **apenas um** dos temas abaixo e desenvolva uma dissertação entre 10 e 20 linhas.

- A) A importância da randomização para a inferência causal.
- B) Correlação não implica causalidade: explique o significado dessa afirmação e apresente um exemplo.
- C) O papel da amostragem na construção de conhecimento científico.
- D) Viés em Ciência de Dados: como ele surge e quais podem ser suas consequências.
- E) Como a visualização de dados pode influenciar a interpretação dos resultados de uma análise.
- F) Por que representatividade é tão importante quanto o tamanho da amostra.

Sua resposta será avaliada pela clareza da argumentação, domínio conceitual e capacidade de relacionar os conceitos estudados na disciplina com situações práticas.