

1. (1 point) Um estudo observacional identificou que pessoas que consomem chocolate regularmente apresentam menor incidência de doenças cardiovasculares.

Explique por que essa observação não é suficiente para concluir que o consumo de chocolate causa melhora da saúde cardiovascular. Cite duas possíveis variáveis de confusão e explique como elas podem afetar a interpretação dos resultados.

Solution: A observação apresentada não é suficiente para estabelecer uma relação de causalidade, pois estudos observacionais permitem identificar associações, mas não garantem que uma variável seja a causa da outra.

Duas possíveis variáveis de confusão são:

- Renda: pessoas com maior renda podem consumir mais chocolate e também ter melhor acesso a serviços de saúde.
- Estilo de vida: indivíduos fisicamente ativos podem apresentar melhor saúde cardiovascular independentemente do consumo de chocolate.

Essas variáveis podem explicar simultaneamente o consumo de chocolate e a redução da incidência de doenças cardiovasculares.

2. (1 point) Explique o papel da randomização em um experimento controlado.

Na sua resposta, descreva:

- (a) O que é um grupo de tratamento;
- (b) O que é um grupo de controle;
- (c) Como a randomização reduz o efeito das variáveis de confusão.

Solution:

- (a) Grupo de tratamento é o grupo que recebe a intervenção ou condição que está sendo estudada.
- (b) Grupo de controle é o grupo que não recebe a intervenção e serve como referência para comparação.
- (c) A randomização distribui os participantes aleatoriamente entre os grupos, reduzindo a influência de variáveis de confusão e tornando os grupos mais comparáveis.

3. (1 point) O conceito de *ceteris paribus* é frequentemente utilizado em estudos observacionais.

Explique:

- (a) O significado da expressão;
- (b) Por que ela é importante na inferência causal;
- (c) Por que é mais difícil obter um cenário *ceteris paribus* em estudos observacionais do que em experimentos controlados.

Solution:

- (a) A expressão *ceteris paribus* significa “mantendo todo o resto constante”.

- (b) Ela é importante porque permite avaliar o efeito de uma variável sem a interferência de outros fatores.
- (c) Em estudos observacionais não existe controle completo sobre os participantes, dificultando a obtenção de grupos equivalentes. Em experimentos controlados a randomização ajuda a aproximar essa condição.

4. (1 point) Considere um estudo que deseja analisar o perfil dos estudantes universitários brasileiros. Foram coletadas respostas apenas de usuários ativos de uma rede social específica.

Explique a diferença entre:

- (a) População-alvo;
- (b) Estrutura de acesso (*access frame*);
- (c) Amostra coletada.

Discuta também como um viés de seleção pode comprometer os resultados do estudo mesmo quando milhões de respostas são obtidas.

Solution:

- (a) População-alvo: todos os estudantes universitários brasileiros.
- (b) Estrutura de acesso (*access frame*): conjunto de indivíduos que podem ser alcançados pela pesquisa.
- (c) Amostra coletada: conjunto dos indivíduos que efetivamente responderam ao questionário.

Mesmo uma amostra muito grande pode produzir resultados enviesados caso determinados grupos da população estejam sub-representados ou ausentes. Esse problema é conhecido como viés de seleção.

5. (1 point) Defina os conceitos de:

- (a) Parâmetro populacional;
- (b) Estimador;
- (c) Estimativa.

Explique por que a média amostral é considerada uma variável aleatória enquanto a média populacional é um valor fixo.

Solution:

- (a) Parâmetro populacional é uma característica da população.
- (b) Estimador é uma regra ou fórmula utilizada para estimar um parâmetro populacional.
- (c) Estimativa é o valor numérico obtido após aplicar um estimador a uma amostra.

A média populacional é fixa porque descreve toda a população. Já a média amostral depende da amostra selecionada e pode variar de uma amostra para outra, sendo portanto uma variável aleatória.

6. (1 point) Considere uma moeda justa.

Explique o que afirma a Lei dos Grandes Números e por que ela é importante para a construção de modelos estatísticos.

Utilize o lançamento de moedas como exemplo.

Solution: A Lei dos Grandes Números afirma que, à medida que o tamanho da amostra aumenta, a média observada tende a se aproximar do valor esperado da população.

Por exemplo, ao lançar uma moeda justa poucas vezes é possível obter resultados bastante diferentes de 50% de caras. Entretanto, com milhares de lançamentos, a proporção observada tende a se aproximar de 50%.

Essa lei fundamenta grande parte da inferência estatística.

7. (1 point) Considere dois modelos de previsão:

- Modelo A: produz resultados muito próximos entre si, porém sistematicamente acima do valor real.
- Modelo B: produz resultados centrados no valor real, porém bastante dispersos.

Identifique qual modelo apresenta:

- (a) Alto viés e baixa variância;
- (b) Baixo viés e alta variância.

Explique os riscos de cada situação para aplicações de Ciência de Dados.

Solution:

(a) Modelo A: alto viés e baixa variância.

(b) Modelo B: baixo viés e alta variância.

O Modelo A produz previsões consistentes porém sistematicamente incorretas. O Modelo B produz previsões corretas em média, mas muito instáveis.

8. (1 point) Classifique cada variável como **discreta** ou **contínua**.

1. Número de alunos matriculados em uma disciplina.
2. Tempo de resposta de um servidor.
3. Quantidade de acessos a um sistema.
4. Altura dos estudantes.
5. Número de erros encontrados em um software.

Justifique suas respostas.

Solution:

Variável	Classificação
Número de alunos matriculados	Discreta
Tempo de resposta de um servidor	Contínua
Quantidade de acessos a um sistema	Discreta
Altura dos estudantes	Contínua
Número de erros encontrados em um software	Discreta

Variáveis discretas são obtidas por contagem. Variáveis contínuas podem assumir infinitos valores em um intervalo.

9. (1 point) Dale e Krueger realizaram um estudo para investigar uma questão bastante discutida: estudantes que frequentam universidades mais prestigiadas realmente obtêm salários maiores por causa da instituição ou porque já eram alunos mais qualificados antes de ingressarem nela?

Para responder a essa pergunta, os pesquisadores analisaram estudantes que haviam se candidatado às mesmas universidades.

- (a) Por que comparar simplesmente alunos de universidades diferentes pode produzir conclusões equivocadas;
- (b) Como o pareamento por aceitações e rejeições ajuda a aproximar um cenário de “*todo o resto igual*”;
- (c) Qual problema metodológico essa estratégia procura reduzir.

Solution:

- (a) Alunos de universidades diferentes podem possuir características prévias distintas, como desempenho acadêmico e renda familiar.
- (b) O pareamento compara estudantes com perfis semelhantes, tornando os grupos mais comparáveis.
- (c) A estratégia procura reduzir o viés de seleção e o efeito das variáveis de confusão.

10. (1 point) Uma pesquisa deseja estimar a média das notas dos estudantes de uma instituição.

Explique:

- (a) Por que o tamanho da amostra influencia a qualidade da estimativa;
- (b) Por que uma amostra grande nem sempre é representativa;
- (c) O que caracteriza uma amostra representativa.

Solution:

- (a) Amostras maiores tendem a produzir estimativas mais precisas.
- (b) Uma amostra grande pode continuar enviesada se não representar adequadamente a população.
- (c) Uma amostra representativa reproduz as características relevantes da população.

11. (1 point) Um cientista de dados precisa apresentar os seguintes resultados para a diretoria:

1. Evolução mensal da taxa de evasão dos alunos ao longo de três anos.
2. Distribuição dos estudantes por curso.
3. Relação entre horas de estudo e nota final dos alunos.

Solution:

1. Gráfico de linhas.
2. Gráfico de barras.
3. Gráfico de dispersão.

O gráfico de linhas representa séries temporais, o gráfico de barras compara categorias e o gráfico de dispersão mostra relações entre variáveis quantitativas.

12. (1 point) Uma empresa apresentou o gráfico abaixo para demonstrar o crescimento das vendas entre 2023 e 2024.
- (a) Por que iniciar o eixo vertical em 950 pode induzir interpretações equivocadas sobre os resultados?
 - (b) O crescimento apresentado parece maior ou menor do que realmente é?
 - (c) Quais princípios de visualização de dados estão sendo violados?
 - (d) Como o gráfico poderia ser redesenhado?
 - (e) Calcule a variação percentual das vendas entre 2023 e 2024.

Solution:

- (a) Iniciar o eixo em 950 amplia visualmente pequenas diferenças.
- (b) O crescimento parece maior do que realmente é.
- (c) Transparência, proporcionalidade visual e integridade gráfica.
- (d) O eixo deveria iniciar em zero ou indicar claramente a quebra da escala.
- (e)

$$\frac{1000 - 980}{980} \times 100 = \frac{20}{980} \times 100 \approx 2.04\%$$

Portanto, as vendas cresceram aproximadamente 2,04%.