

Atividade de Fixação 1 – Inferência Estatística e TLC (N2)

Apresentação da Atividade

Esta atividade de fixação abrange as propriedades da média, variabilidade, Teorema do Limite Central (TLC) e introdução aos Intervalos de Confiança. As questões visam consolidar a base estatística clássica indispensável para o entendimento de testes empíricos de hipóteses.

Questões Teóricas e Computacionais

Questão 1 Demonstre matematicamente que a soma dos desvios de um conjunto de dados $\{x_1, x_2, \dots, x_N\}$ em relação à sua média amostral $\bar{X}$ é igual a zero. Ou seja, prove que:

$$\sum_{i=1}^N (x_i - \bar{X}) = 0$$

Questão 2 Em termos geométricos e analíticos, explique qual a propriedade que diferencia a média da mediana em relação à minimização de erros de previsão.

Dica: Compare a minimização da soma dos desvios absolutos ($\sum |x_i - c|$) com a soma dos desvios quadrados ($\sum (x_i - c)^2$).

Questão 3 Explique a regra empírica da Curva Normal (Regra 68-95-99.7). Se a distribuição dos salários de uma empresa cearense é aproximadamente normal, com média de R\$ 3.500,00 e desvio padrão de R\$ 400,00, qual é a proporção esperada de funcionários que recebem:

- a) Entre R\$ 3.100,00 e R\$ 3.900,00?
- b) Entre R\$ 2.700,00 e R\$ 4.300,00?
- c) Mais do que R\$ 4.700,00?

Questão 4 O Teorema do Limite Central (TLC) é considerado o pilar da inferência estatística clássica.

- a) Enuncie o Teorema do Limite Central em termos simples, explicando o que acontece com a distribuição das médias amostrais à medida que o tamanho da amostra (N) cresce.
- b) Explique a diferença conceitual entre o desvio padrão da população (σ) e o Erro Padrão da Média (SE). Qual a relação matemática entre eles?

Questão 5 Deseja-se estimar a média de consumo diário de água por habitante em uma cidade do Sertão dos Inhamuns. Sabendo que o desvio padrão histórico é de 30 litros por dia, calcule o tamanho de amostra (N) necessário para que o erro da estimativa (margem de erro) não ultrapasse 3 litros, com um nível de confiança de 95% ($z \approx 1.96$).

Questão 6 Explique o significado exato da frase: “*Construímos um Intervalo de Confiança de 95% para a média populacional μ que resultou em $[150, 180]$* ”. É correto dizer que existe 95% de probabilidade de o parâmetro populacional μ estar contido neste intervalo específico? Justifique sua resposta com base na definição teórica frequentista de probabilidade.

Gabarito Comentado e Dicas de Resolução

Dica de Estudo

Use as resoluções comentadas abaixo para verificar suas respostas e orientar sua preparação para a avaliação teórica presencial.

Resolução 1: A soma dos desvios em relação à média é expressa por:

$$\sum_{i=1}^N (x_i - \bar{X}) = \sum_{i=1}^N x_i - \sum_{i=1}^N \bar{X}$$

Como $\bar{X}$ é uma constante para a amostra, somá-la N vezes equivale a multiplicá-la por N :

$$\sum_{i=1}^N (x_i - \bar{X}) = \sum_{i=1}^N x_i - N\bar{X}$$

Pela definição de média amostral, temos $\bar{X} = \frac{1}{N} \sum x_i \Rightarrow N\bar{X} = \sum x_i$. Substituindo:

$$\sum_{i=1}^N (x_i - \bar{X}) = \sum_{i=1}^N x_i - \sum_{i=1}^N x_i = 0 \quad \blacksquare$$

Resolução 2: A **média** amostral minimiza a soma dos erros quadráticos ($\sum (x_i - c)^2$), sendo o ponto de equilíbrio geométrico das distâncias elevadas ao quadrado (mínimos quadrados), o que a torna sensível a valores extremos (*outliers*). A **mediana** minimiza a soma dos desvios absolutos ($\sum |x_i - c|$), caracterizando-se como o valor central da distribuição ordenada de dados (mais robusto a *outliers*).

Resolução 3: Dados: $\mu = 3500$, $\sigma = 400$.

- a) Intervalo $[3100, 3900]$ corresponde a $\mu \pm 1\sigma$. Pela regra empírica, contém aproximadamente **68%** dos dados.
- b) Intervalo $[2700, 4300]$ corresponde a $\mu \pm 2\sigma$, contendo aproximadamente **95%** dos dados.
- c) R\$ 4.700,00 equivale a $\mu + 3\sigma$. A área total externa ao intervalo de 3σ ($\pm 3\sigma$) é $100\% - 99.7\% = 0.3\%$. Como a distribuição normal é perfeitamente simétrica, a cauda direita (acima de 3σ) possui metade dessa área: $0.3\%/2 = \mathbf{0.15\%}$.

Resolução 4: a) O TLC enuncia que para qualquer população de média μ e desvio padrão σ , a distribuição da média amostral $\bar{X}$ se aproxima de uma distribuição normal com média μ e desvio padrão $SE = \sigma/\sqrt{N}$, conforme o tamanho da amostra N tende ao infinito (na prática, $N \geq 30$).

b) O desvio padrão (σ) mede a dispersão de observações individuais. O Erro Padrão (SE) mede a variabilidade amostral da estimativa da média. Sua relação matemática é dada por $SE = \sigma/\sqrt{N}$.

Resolução 5: A margem de erro desejada é $E \leq 3$, com desvio padrão $\sigma = 30$ e $z = 1.96$. A fórmula da margem de erro é:

$$E = z \cdot \frac{\sigma}{\sqrt{N}} \Rightarrow 3 = 1.96 \cdot \frac{30}{\sqrt{N}} \Rightarrow \sqrt{N} = 19.6 \Rightarrow N = 19.6^2 = 384.16$$

Arredondando para cima, necessitamos de uma amostra de no mínimo **385 habitantes**.

Resolução 6: Significa que o método de construção de intervalos de confiança acerta em 95% das reamostragens possíveis. **Não é correto** atribuir probabilidade de 95% ao intervalo $[150, 180]$ já calculado, pois a média real μ é uma constante fixa (embora desconhecida). Logo, o intervalo específico $[150, 180]$ contém ou não contém a média μ (probabilidade 1 ou 0). A confiança é uma propriedade estatística do *processo amostral*, não de um resultado numérico fixado.